Clasificación de la popularidad de artículos online

PAC1 - Modelización de Datos Complejos | GEA UAB

Manuela López Cambrón (1673688) Abril P. Lozano Díaz (1670769)
Àlex Hinojal Rodríguez (1670853)

2026-06-05

Contents

1 Introducción **2**
1.1 Objetivo . . . 2
1.2 Base de datos . . . 3
1.3 Selección inicial de variables . . . 3
1.4 Presentación de las variables . . . 4

2 Preprocessing **6**
2.1 Depuración de la base de datos . . . 6
2.2 Construcción de la variable objetivo . . . 6
2.3 Discretización de variables continuas . . . 7
2.4 Selección automática de variables mediante Markov Blanket . . . 25
2.5 Base de datos final . . . 27

3 Análisis descriptivo **29**
3.1 Distribución de la variable objetivo . . . 29
3.2 Variables de la base reducida . . . 30
3.3 Distribución de las variables predictoras . . . 31
3.4 Relación descriptiva con la popularidad . . . 31
3.5 Conclusión del análisis descriptivo . . . 32

4 Selección de modelos **33**
4.1 Modelos propuestos . . . 33
4.2 Metodología de evaluación . . . 33
4.3 Comparación de modelos . . . 38
4.4 Modelos finales . . . 42

5 Modelo Principal: Naive Bayes con Ord-Map **43**

5.1 Estructura del modelo final 43

5.2 Capacidad discriminativa de las variables 45

5.3 Probabilidades posteriores 46

5.4 Capacidad predictiva del modelo 48

5.5 Estudio de predicciones 48

6 Modelo secundario: relaciones entre predictoras **51**

7 Análisis complementario: estudio de asociación entre predictoras y respuesta **53**

7.1 Motivación del análisis complementario 53

7.2 Resultados 53

8 Conclusiones **54**

9 Limitaciones y propuestas de mejora **55**

1 Introducción

En el contexto actual, los medios digitales publican diariamente una gran cantidad de noticias y artículos online. Todos estos contenidos compiten por captar la atención de los usuarios, por lo que resulta interesante estudiar qué características pueden estar relacionadas con que una noticia sea más o menos popular.

En este trabajo, la popularidad de un artículo se mide a partir del número de veces que ha sido compartido. Esta variable es útil porque permite aproximar el impacto que ha tenido una publicación entre los lectores. Sin embargo, en lugar de predecir directamente el número exacto de compartidos, se ha decidido clasificar los artículos en distintos niveles de popularidad. De esta forma, el problema se plantea como una tarea de clasificación.

La finalidad principal del trabajo es estudiar si, a partir de las características de un artículo, es posible predecir su nivel de popularidad. Para ello, se utilizan variables relacionadas con el canal de publicación, el momento en que se publica la noticia, la longitud del texto, el número de enlaces, imágenes o vídeos, las palabras clave y algunas medidas relacionadas con la subjetividad y la polaridad del contenido.

Para realizar este análisis se emplean redes bayesianas, que son modelos probabilísticos que permiten estudiar relaciones entre variables y hacer predicciones. En concreto, se comparan distintos modelos de clasificación bayesiana para analizar cuál funciona mejor en este problema. Estos modelos son adecuados porque permiten trabajar con variables categóricas y, además, sus resultados pueden interpretarse de forma relativamente clara.

1.1 Objetivo

El objetivo es construir, evaluar e interpretar modelos de clasificación capaces de predecir el nivel de popularidad de artículos online a partir de sus características editoriales, textuales y contextuales. En concreto, se trabaja con artículos publicados en Mashable y se utiliza como punto de partida la variable `shares`, que recoge el número de veces que cada noticia fue compartida. Dado que este número de compartidos es una medida directa de difusión, lo tomamos como indicador de popularidad del artículo dentro del entorno digital.

El propósito del análisis no es predecir de forma exacta el número de compartidos, sino transformar este problema en una tarea de clasificación ordinal. Para ello hemos recodificado la variable `shares` ya que no interesa únicamente saber cuántas veces se compartirá una noticia, anticipar si tendrá una popularidad baja, media o alta en comparación con el resto de artículos de la base de datos.

Desde el punto de vista metodológico, el estudio se centra en el uso de redes bayesianas para clasificación. Comparamos distintas estructuras de modelo, como Naive Bayes, Tree-Augmented Naive Bayes y un modelo tipo Prognosi, además de distintos criterios de predicción, concretamente MAP y Ord-MAP. Esta comparación permite valorar si resulta más adecuado emplear modelos simples y parsimoniosos o estructuras más flexibles que permitan representar relaciones adicionales entre variables predictoras. Al tratarse de una variable objetivo ordinal y con cierto desbalance entre clases, se utilizan métricas de evaluación que tienen en cuenta estas características, especialmente el AMAE, junto con Accuracy, Balanced Accuracy, MAE y matrices de confusión.

Los objetivos específicos del trabajo son los siguientes:

- Preparar y depurar la base de datos original para conservar únicamente observaciones informativas y coherentes con el objetivo del análisis.
- Construir una variable objetivo ordinal e interpretable a partir del número de compartidos (`shares`).
- Realizar una selección inicial de variables predictoras basada en criterios lógicos, interpretativos y relacionados con el proceso de difusión de una noticia.
- Crear una variable categórica `channel` que sintetice las variables dummy originales del canal de publicación y facilite la interpretación del modelo.

- Discretizar las variables continuas seleccionadas para poder trabajar con redes bayesianas de variables categóricas.
- Aplicar un proceso de selección automática mediante Markov Blanket para obtener una base reducida de variables relevantes.
- Entrenar y comparar diferentes modelos bayesianos de clasificación utilizando validación cruzada estratificada.
- Seleccionar un modelo principal atendiendo tanto al rendimiento predictivo como a la parsimonia.
- Interpretar las relaciones entre variables y popularidad mediante el modelo final y mediante análisis complementarios de asociación.

Por un lado, se busca obtener un clasificador que permita asignar a cada artículo un nivel esperado de popularidad. Por otro lado, se pretende comprender qué características de los artículos se relacionan con una mayor o menor difusión dentro de la base de datos analizada.

1.2 Base de datos

La base de datos utilizada es *Online News Popularity*, un conjunto de datos formado por artículos publicados en Mashable. La base original contiene 39.644 noticias online y 61 variables, entre las que se incluyen características del contenido, del título, del canal de publicación, del momento de publicación, de las palabras clave y de medidas relacionadas con la subjetividad y la polaridad textual.

La variable de interés original es `shares`, que indica el número de veces que cada artículo fue compartido. Esta variable se utiliza como punto de partida para construir la variable objetivo del estudio. Sin embargo, `shares` presenta una distribución muy asimétrica, con una fuerte concentración de artículos poco compartidos y algunos valores extremadamente altos. Este comportamiento es habitual; pocos contenidos alcanzan mucha visibilidad y la mayoría obtiene una difusión moderada o baja.

Por este motivo, en lugar de modelizar directamente `shares` como variable numérica, se decide transformarla en una variable ordinal de popularidad. Esta decisión tiene varias ventajas. Reduce el efecto de los valores extremos, permite formular el problema como una clasificación por niveles, que resulta más fácil de interpretar, se adapta mejor al enfoque de redes bayesianas utilizado posteriormente, ya que el interés del trabajo está en clasificar la popularidad en categorías y no en estimar un valor exacto de compartidos.

Antes de la modelización, la base de datos se somete a un proceso de depuración. Aunque no se detectan valores faltantes, sí se identifican 1.181 observaciones con `n_tokens_content = 0`, es decir, artículos sin contenido textual registrado.

La base de datos contiene variables de distinta naturaleza. Algunas son numéricas, como el número de tokens del título, el número de tokens del contenido, el número de enlaces, imágenes o vídeos. Otras son binarias, como las variables que indican el día de publicación o el canal temático del artículo. También aparecen variables continuas construidas a partir de análisis textual, como la subjetividad global, la polaridad positiva media, la polaridad negativa media o la polaridad del título. Esta variedad de información permite abordar la popularidad de los artículos desde una perspectiva amplia, combinando elementos de contenido, formato, temática y tono.

1.3 Selección inicial de variables

La selección inicial de variables se realizó siguiendo un criterio lógico e interpretativo. Dado que la base original contiene un número elevado de variables, no se consideró adecuado incorporar todas directamente al modelo. El objetivo de esta primera selección fue conservar aquellas variables que, antes de aplicar métodos automáticos, tuvieran una relación razonable con la popularidad de un artículo online y pudieran interpretarse de forma clara dentro del problema.

Se priorizaron características que pudieran utilizarse para anticipar la popularidad sin depender de información posterior al comportamiento de los usuarios. Bajo este criterio, se incluyeron variables relacionadas con

el tema de la noticia, el momento de publicación, la longitud del texto y del título, los recursos multimedia, la presencia de enlaces, el historial de popularidad de palabras clave y el tono subjetivo o emocional del contenido.

En primer lugar, se seleccionaron variables asociadas al **tema y momento de publicación**. El canal temático puede influir en la difusión porque no todos los temas generan el mismo interés ni se comparten con la misma frecuencia. También se mantuvo la variable `is_weekend`, ya que publicar en fin de semana puede afectar a la visibilidad y al comportamiento de lectura o difusión de los usuarios.

En segundo lugar, se incorporaron variables relacionadas con la **longitud del artículo y del título**, concretamente `n_tokens_content` y `n_tokens_title`. La longitud puede influir en la forma en que los usuarios consumen y comparten una noticia. Un texto demasiado corto puede contener poca información, mientras que uno muy largo puede exigir más tiempo de lectura. Del mismo modo, la longitud del título puede afectar a la capacidad del artículo para captar la atención inicial del lector.

En tercer lugar, se consideraron variables vinculadas a los **recursos incluidos en el artículo**, como `num_hrefs`, `num_imgs` y `num_videos`. Estas variables recogen el número de enlaces, imágenes y vídeos presentes en el contenido. Su inclusión se justifica porque los elementos multimedia y los enlaces pueden enriquecer el artículo, hacerlo más atractivo o aumentar su credibilidad, factores que podrían influir en su difusión.

En cuarto lugar, se seleccionó `kw_avg_avg`, una variable relacionada con la **popularidad histórica media de las palabras clave** asociadas al artículo. Esta variable resulta especialmente relevante porque resume información previa sobre el rendimiento de términos similares. Si un artículo utiliza palabras clave que históricamente han estado asociadas a contenidos muy compartidos, es razonable pensar que puede tener mayor probabilidad de alcanzar niveles altos de popularidad.

Finalmente, se incorporaron variables de **subjetividad y polaridad**, tanto del contenido como del título. Estas variables permiten estudiar si el tono del artículo se relaciona con la difusión. Se incluyeron `global_subjectivity`, `avg_positive_polarity`, `avg_negative_polarity`, `title_subjectivity`, `title_sentiment_polarity` y `abs_title_sentiment_polarity`. La lógica de esta elección es que los contenidos con mayor carga subjetiva o emocional pueden generar más reacción en los lectores y, por tanto, una mayor tendencia a ser compartidos.

Un punto importante de esta fase fue el tratamiento de las variables del canal de publicación. En la base original, el canal aparece representado mediante varias variables dummy, como `data_channel_is_lifestyle`, `data_channel_is_entertainment`, `data_channel_is_bus`, `data_channel_is_socmed`, `data_channel_is_tech` y `data_channel_is_world`. En lugar de conservar todas estas dummies por separado, se creó una única variable categórica llamada `channel`, que recoge el canal de publicación de cada artículo. Cuando ninguna de las dummies principales estaba activada, el artículo se clasificó dentro de la categoría `other`.

La decisión de crear `channel` y utilizarla en lugar de las variables dummy originales se tomó por varios motivos. En primer lugar, mejora la interpretabilidad, ya que es más claro hablar de una variable con categorías de canal que de varias variables binarias separadas. En segundo lugar, evita introducir información redundante, porque las dummies del canal representan niveles de una misma característica. En tercer lugar, facilita la modelización bayesiana, ya que el canal se trata como una única variable categórica con varios estados posibles. Por tanto, `channel` resume de forma más natural la información temática del artículo y permite comparar directamente la popularidad asociada a cada tipo de canal.

Tras esta selección inicial, el conjunto de variables candidatas quedó formado por 14 predictoras. Estas variables no constituyen todavía la base definitiva del modelo, sino un conjunto razonado de variables relevantes que posteriormente se discretizan y se someten a una segunda selección mediante Markov Blanket.

1.4 Presentación de las variables

Las variables seleccionadas inicialmente se agrupan en distintos bloques interpretativos, según el tipo de información que aportan sobre cada artículo. Esta organización facilita la lectura del conjunto de predictoras

y permite justificar que no se han escogido únicamente variables aisladas, sino dimensiones relevantes del contenido, del momento de publicación y del estilo del artículo.

```
## Warning in styling_latex_scale(out, table_info, "down"): Longtable cannot be
## resized.
```

Table 1: Variables seleccionadas inicialmente para el análi
ularidad de artículos online.

Bloque	Variable	Descripción
Publicación	\texttt{channel}	Canal o temática principal del artículo.
Publicación	\texttt{is_weekend}	Indica si el artículo fue publicado en fin de semana.
Longitud	\texttt{n_tokens_content}	Número de palabras del contenido del artículo.
Longitud	\texttt{n_tokens_title}	Número de palabras del título.
Recursos del artículo	\texttt{num_hrefs}	Número de enlaces incluidos en el artículo.
Recursos del artículo	\texttt{num_imgs}	Número de imágenes incluidas en el artículo.
Recursos del artículo	\texttt{num_videos}	Número de vídeos incluidos en el artículo.
Palabras clave	\texttt{kw_avg_avg}	Popularidad media histórica asociada a las palabras clave del a
Subjetividad y polaridad	\texttt{global_subjectivity}	Nivel global de subjetividad del contenido.
Subjetividad y polaridad	\texttt{avg_positive_polarity}	Polaridad positiva media del contenido.
Subjetividad y polaridad	\texttt{avg_negative_polarity}	Polaridad negativa media del contenido.
Título	\texttt{title_subjectivity}	Nivel de subjetividad del título.
Título	\texttt{title_sentiment_polarity}	Polaridad sentimental del título.
Título	\texttt{abs_title_sentiment_polarity}	Intensidad absoluta de la polaridad del título.

Nota: Las variables se agrupan según el tipo de información que aportan al análisis. En fases posteriores del preprocesamiento, las

Antes de entrenar los modelos bayesianos, fue necesario transformar varias variables de la base de datos en variables categóricas. Esta decisión se debe a que las redes bayesianas utilizadas en este trabajo se aplican sobre variables discretas, por lo que las variables numéricas seleccionadas debían recodificarse en niveles interpretables.

No todas las transformaciones realizadas tienen la misma naturaleza. En primer lugar, la variable objetivo original `shares`, que recoge el número de veces que un artículo fue compartido, se transformó en la variable ordinal `popularidad`. Esta nueva variable clasifica los artículos en distintos niveles de difusión: `muy_baja`, `baja`, `media` y `alta`. De esta forma, el problema deja de plantearse como una predicción exacta del número de compartidos y pasa a formularse como una tarea de clasificación ordinal.

En segundo lugar, las variables dummy originales que indicaban el canal temático del artículo se agruparon en una única variable categórica llamada `channel`. Esta transformación permite representar el tema de publicación de forma más compacta e interpretable. En lugar de trabajar con varias columnas binarias, una para cada posible canal, se utiliza una sola variable con distintos niveles, como `lifestyle`, `entertainment`, `business`, `socmed`, `tech`, `world` u `other`.

Por último, las variables predictoras numéricas seleccionadas se discretizaron creando nuevas variables categóricas con el sufijo `_cat`. En general, estas variables se agruparon en niveles como bajo, medio y alto, utilizando como referencia la distribución de cada variable. En particular, se tuvo en cuenta el primer y tercer cuartil para separar valores relativamente bajos, valores centrales y valores relativamente altos. No obstante, en algunas variables se realizaron ajustes manuales cuando la distribución lo requería, especialmente en aquellas con una elevada concentración de ceros.

2 Preprocessing

2.1 Depuración de la base de datos

Valores faltantes

Nuestra base de datos no cuenta con ningún valor faltante, de manera que no se han descartado casos por este motivo.

Casos sin información

Por otro lado, si se han detectado 1181 casos que han sido considerados sin valor informativo o incluso posibles distorsionadores del estudio. El criterio está fundamentado en la variable `n_tokens_content`, donde dichos casos pesentan valor 0, es decir ausencia de texto. Estas observaciones probablemente procedan de artículos cuyo único contenido son archivos multimedia, o incluso fallos de recopilación. Debido a la baja proporción que representan dentro de nuestro conjunto, han sido eliminados, enfocando así nuestro estudio hacia artículos con contenido textual. Esta decisión encaja perfectamente con la intención de analisis, ya que muchas de las predictoras se basan en características propias del texto publicado. La base de datos finalmente trabajada contará con 38463 observaciones válidas

2.2 Construcción de la variable objetivo

Nuestra variable objetivo original, como la mayoría de predictoras, es de carácter numérico discreto por lo que debemos emplear un criterio de disretización que nos permita tanto reflejar su naturaleza interpretativa como equilibrar las clases resultantes para un análisis satisfactorio. La idea del método ejecutado se basa en un escalado que nos permite interpretar la popularidad de cada noticia dentro dentro del conjunto de todas.

Partimos de la variable numérica `shares`, la cual está fuertemente sesgada con valores extremos que distorsionan la distribución, concretamente hacia la cola derecha. Extraemos los valores de dicha variables en un vector llamado `shares` para poder trabajarla.

Nuestro primer paso será eliminar temporalmente sus outliers mediante el método del rango intercuartílico. Creamos el vector `shares2`, que contiene únicamente los valores no atípicos de `shares`. Ahora con estos datos estables procedemos a su recodificación.

Redefinimos `shares2`como un vector con los valores de `shares` normalizados por el valor máximo de `shares2` (incluidos los valores atípicos). De esta manera lo que estamos haciendo es asignar una nota de popuralidad a cada noticia cogiendo como referencia de popularidad máxima el máximo valor no atípico de compartidos. Consecuentemente las observaciones quedan escaladas con una puntuación entre 0 y 100 para aquellas no atípicas y mayores a 100 en aquellas atípicas.

Finalmente utilizamos esta nueva codificación de la variable para crear nuestros niveles en función de la nota asignada, el cual es un criterio muy interpretativo. Inicialmente se plantearon los siguientes cortes:

- [0,50) para popularidad baja
- [50,90) para popularidad media
- [90, ∞] para popularidad alta

Sin embargo, se detecto que la gran mayoría de los artículos se catalogaban como popularidad baja, lo cual nos dejaba con clases fuertemente desbalanceadas, por lo que se agregó otro nivel para dividir dicha categoría:

- [0,20) para popularidad muy baja
- [20,50) para popularidad baja

- [50,90) para popularidad media
- [90, ∞] para popularidad alta

La discretización mediante estos cortes se aplicó al vector `shares2`generando así el vector `popularidad` que fue añadido a la base de datos en sustitución del inicial `shares`. Esta nueva variable `popularidad` es nuestra variable objetivo.

A continuación se presenta un pequeño ejemplo con algunos casos que ilustre el proceso:

```
##  shares shares2 popularidad
##     593   10.78    muy_baja
##     711   12.93    muy_baja
##    1500   27.27        baja
##    1200   21.82        baja
##     505    9.18    muy_baja
##     855   15.55    muy_baja
##     556   10.11    muy_baja
##     891   16.20    muy_baja
##    3600   65.45       media
##     710   12.91    muy_baja
##    2200   40.00        baja
##    1900   34.55        baja
##     823   14.96    muy_baja
##   10000  181.82        alta
##     761   13.84    muy_baja
##    1600   29.09        baja
##   13600  247.27        alta
##    3100   56.36       media
##    5700  103.64        alta
##   17100  310.91        alta
```

La distribución en niveles queda de la siguiente manera:

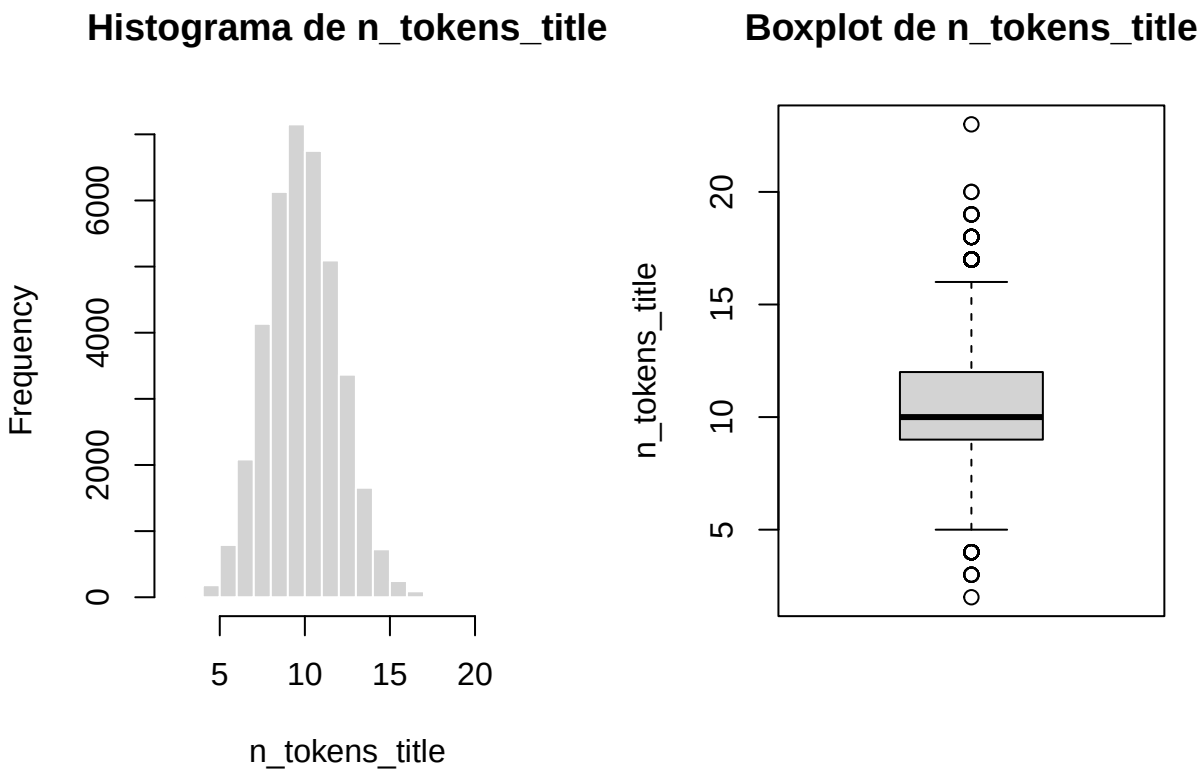
```
##
## muy_baja     baja    media     alta
##    12424    17231     4809     5180
```

2.3 Discretización de variables continuas

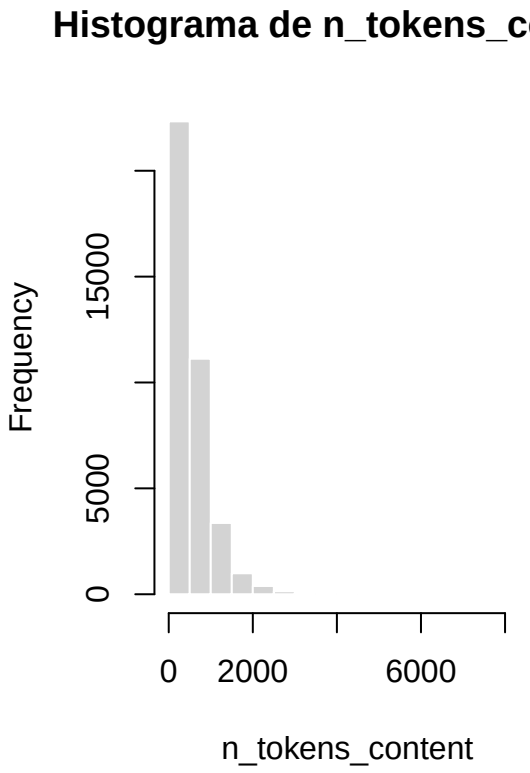
Del conjunto de las 14 variables predictoras seleccionadas, 12 son numéricas. Para el trabajo con redes bayesianas es necesario transformarlas en categóricas, priorizando un criterio interpretativo.

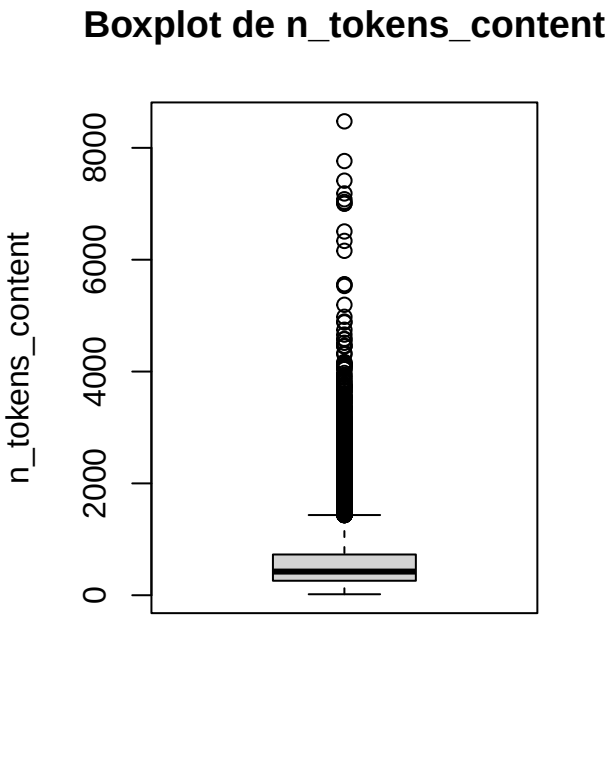
Para conocer su distribución y así poder tomar decisiones formadas, presentamos un pequeño análisis descriptivo de cada predictora, enfocado a dicho objetivo:

```
##
## ===================================
## Variable: n_tokens_title
## ===================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     2.000     6.000     7.000     8.000     9.000    10.000    10.382
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##    12.000    13.000    14.000    15.000    23.000     0.000     0.000
```

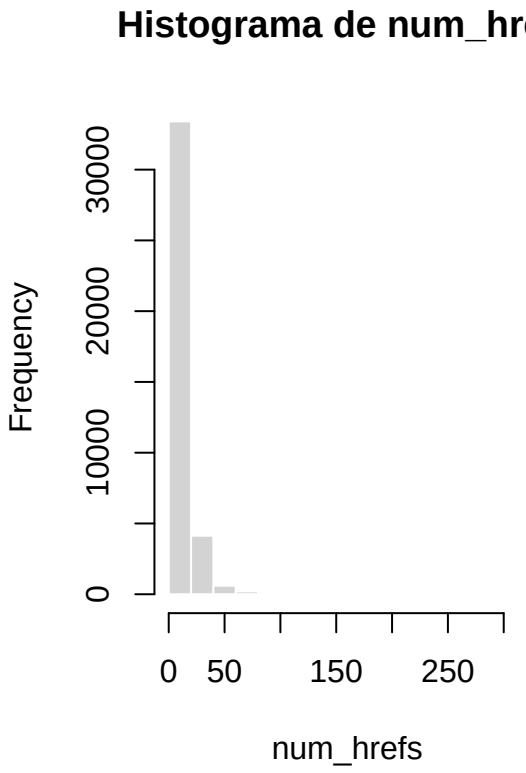


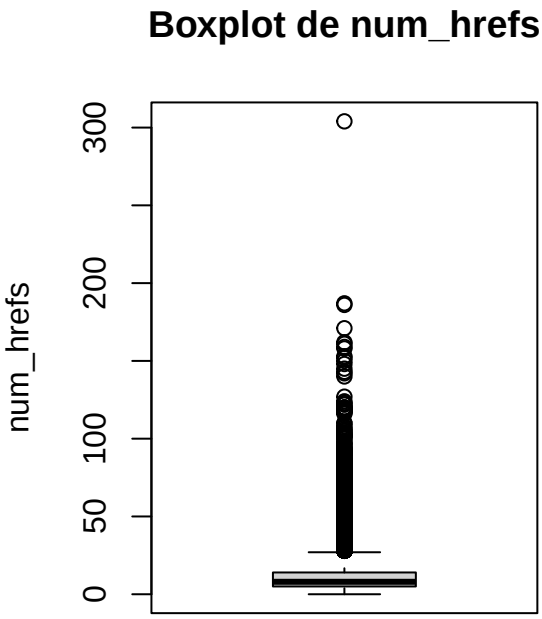

```
##
## ==================================
## Variable: n_tokens_content
## ==================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000    18.000    88.620   135.000   171.000   259.000   423.000   563.295
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##   729.000  1100.000  1423.900  2284.000  8474.000     0.000     0.000
```



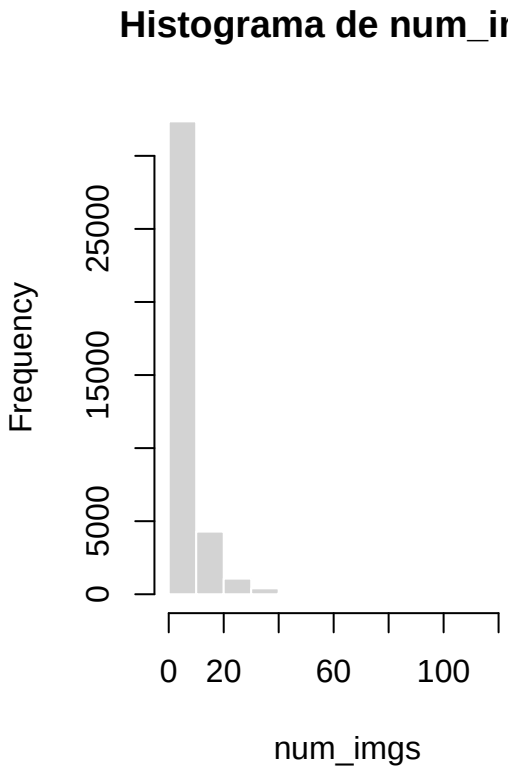


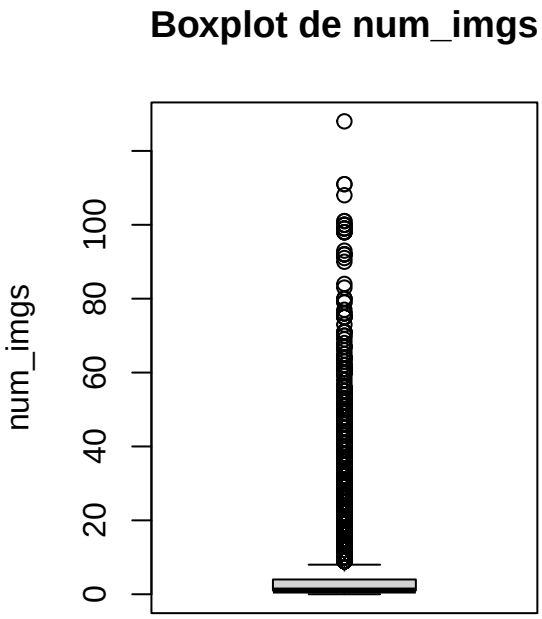

```
##
## ==================================
## Variable: num_hrefs
## ==================================
##         n       min     p01.1%     p05.5%   p10.10%     Q1.25%   mediana      media
## 38463.000     0.000      1.000      2.000     3.000      5.000     8.000     11.218
##    Q3.75%   p90.90%   p95.95%   p99.99%        max      ceros pct_ceros
##    14.000    23.000    31.000    56.000   304.000    118.000     0.307
```



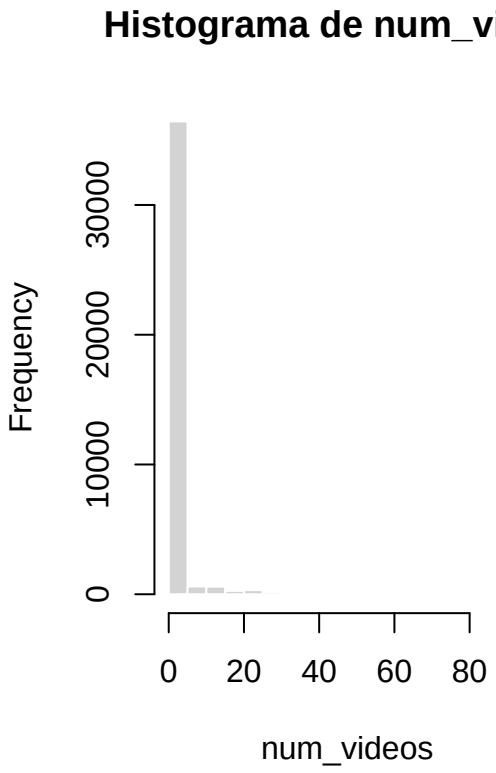


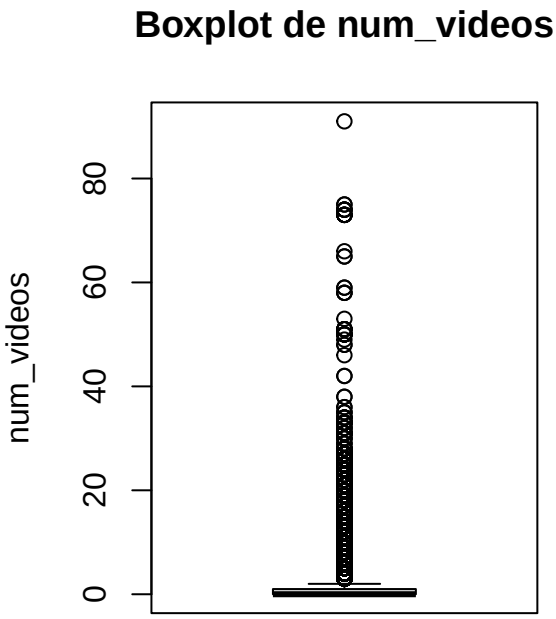

```
##
## ==================================
## Variable: num_imgs
## ==================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000     0.000     0.000     0.000     1.000     1.000     4.563
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     4.000    14.000    20.000    37.000   128.000  6170.000    16.041
```



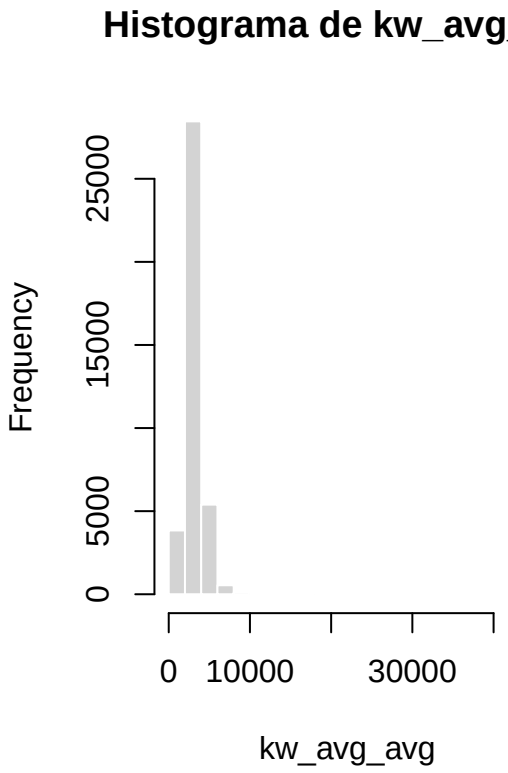


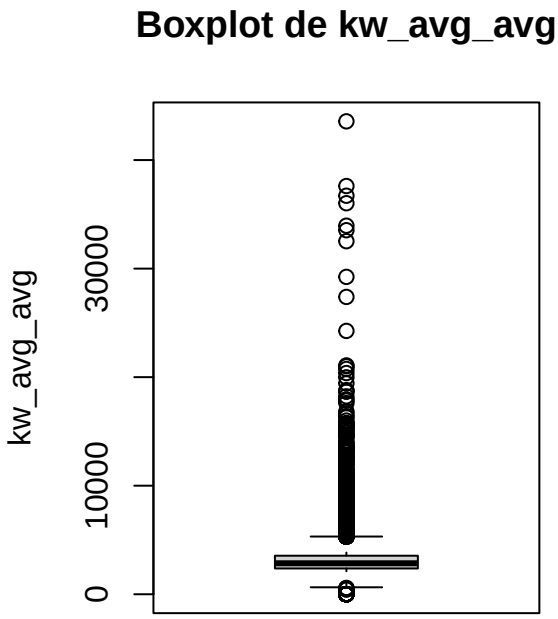

```
##
## ==================================
## Variable: num_videos
## ==================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000     0.000     0.000     0.000     0.000     0.000     1.264
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     1.000     2.000     6.000    21.000    91.000 24661.000    64.116
```



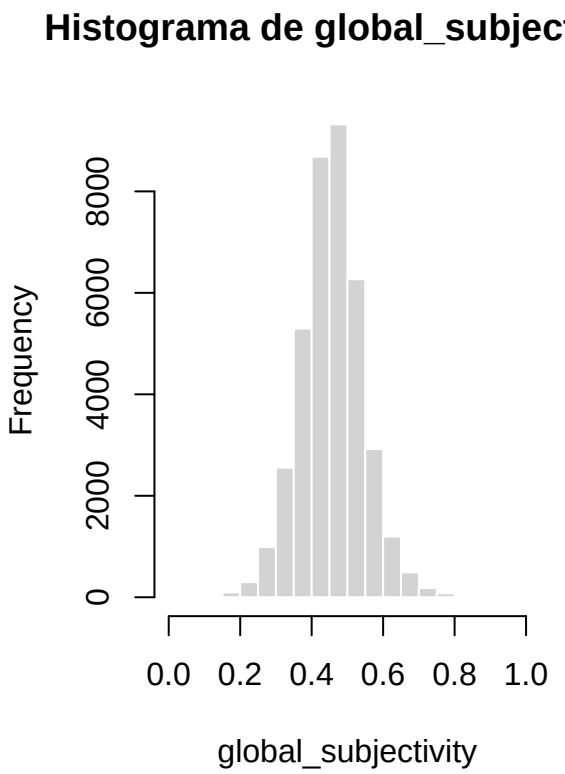


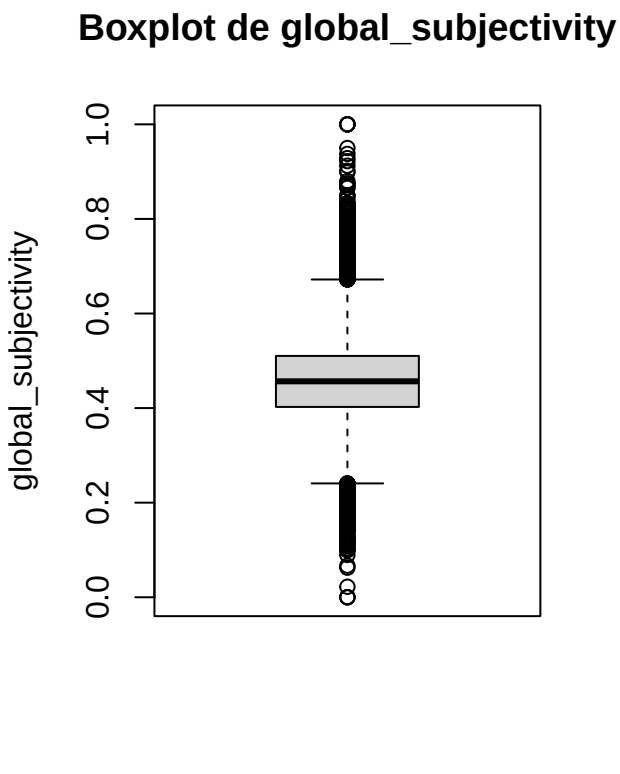

```
##
## ====================================
## Variable: kw_avg_avg
## ====================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000  1334.092  1779.962  2000.638  2373.807  2850.847  3103.428
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##  3550.518  4470.287  5126.155  6940.213 43567.660    79.000     0.205
```



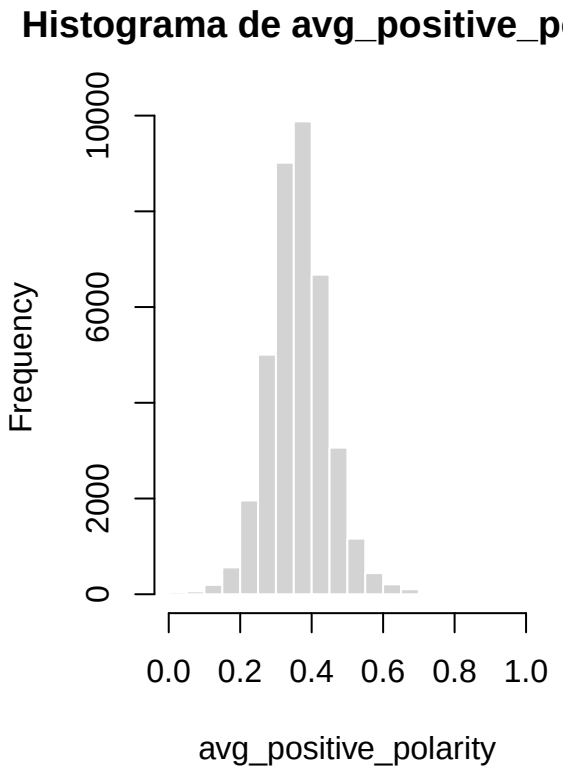


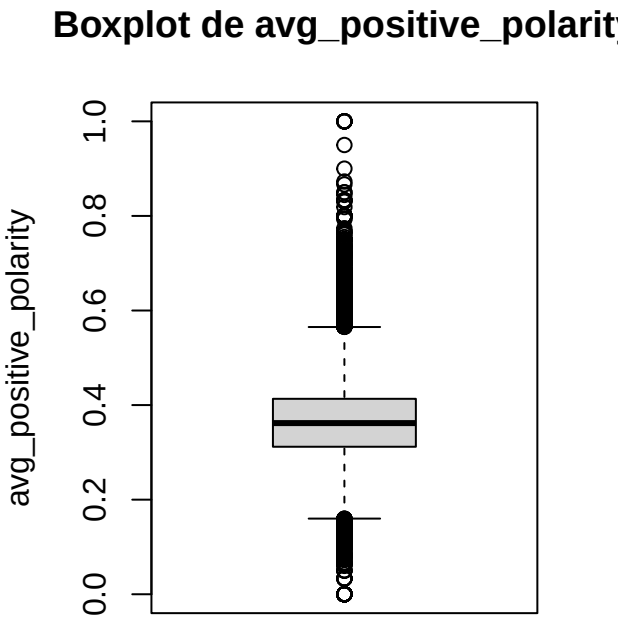

```
##
## ===================================
## Variable: global_subjectivity
## ===================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000     0.245     0.314     0.348     0.402     0.457     0.457
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     0.510     0.563     0.602     0.687     1.000     3.000     0.008
```



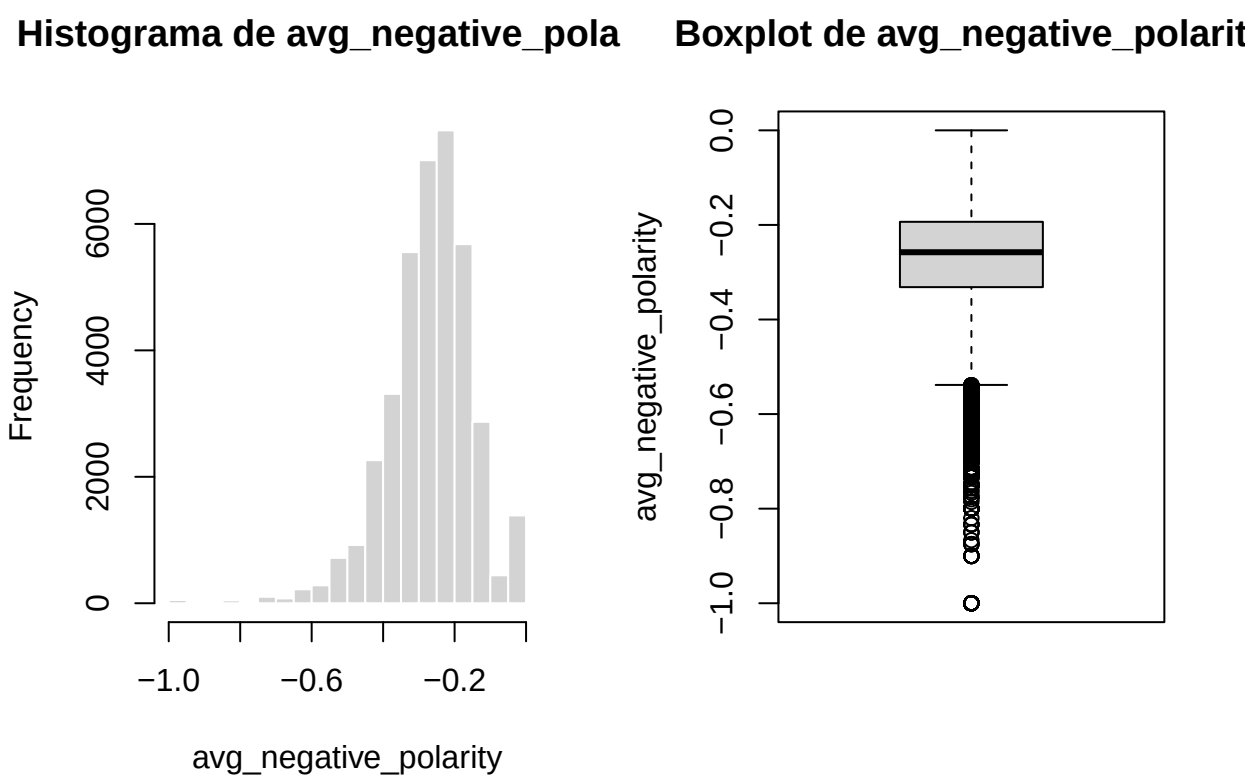



```
##
## ===================================
## Variable: avg_positive_polarity
## ===================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000     0.162     0.234     0.264     0.312     0.362     0.365
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     0.413     0.467     0.502     0.605     1.000    36.000     0.094
```

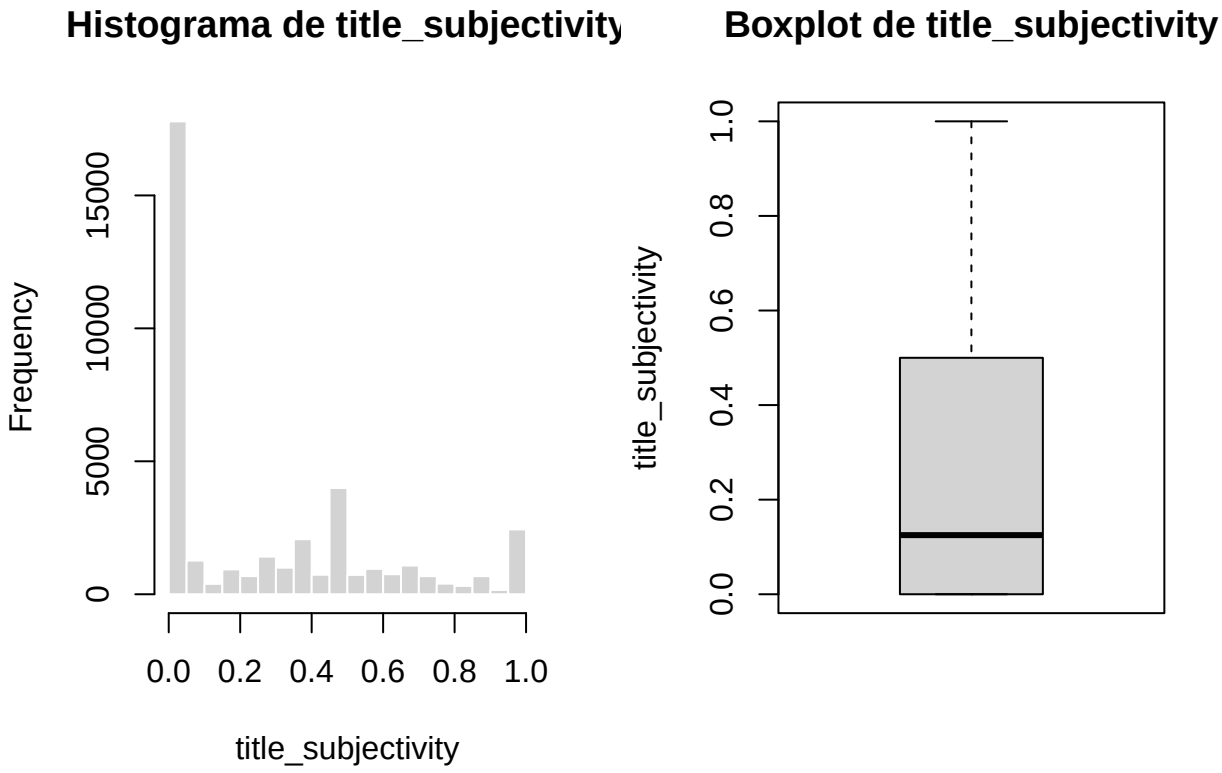




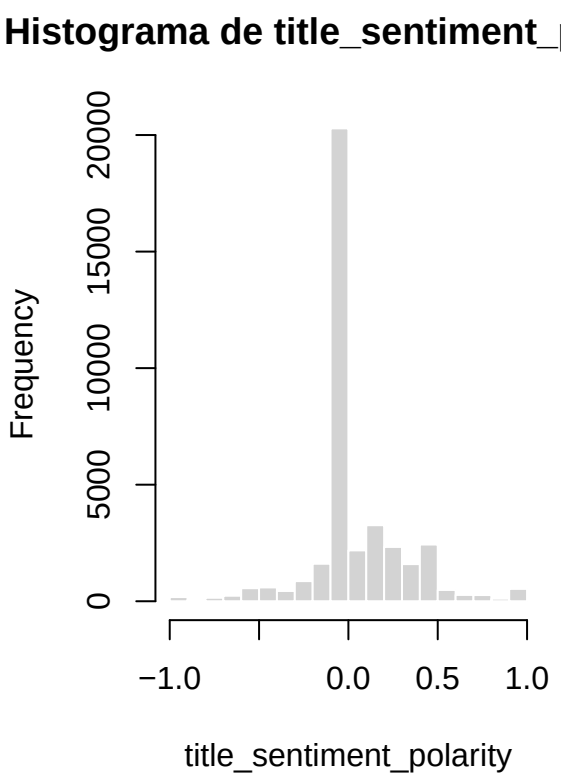

```
##
## ===================================
## Variable: avg_negative_polarity
## ===================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000    -1.000    -0.620    -0.470    -0.411    -0.332    -0.258    -0.267
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##    -0.193    -0.136    -0.100     0.000     0.000  1369.000     3.559
```

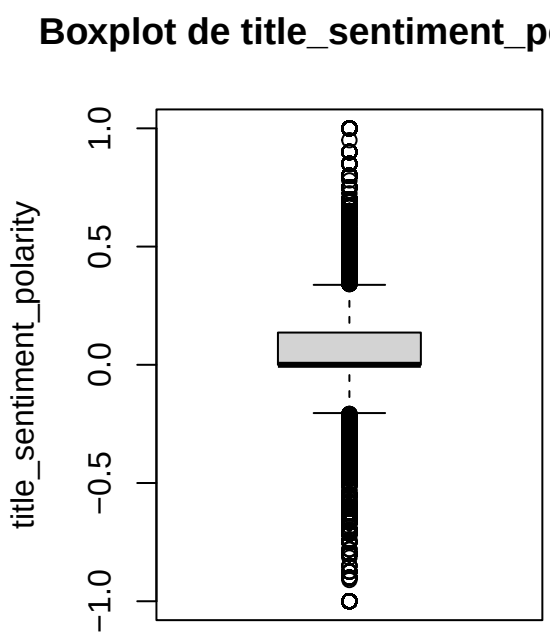



```
##
## ===================================
## Variable: title_subjectivity
## ===================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000     0.000     0.000     0.000     0.000     0.125     0.281
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     0.500     0.800     1.000     1.000     1.000 17553.000    45.636
```

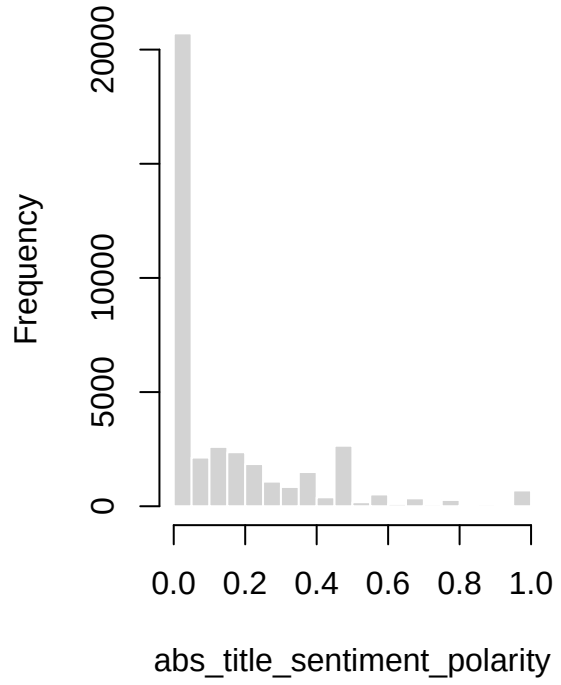


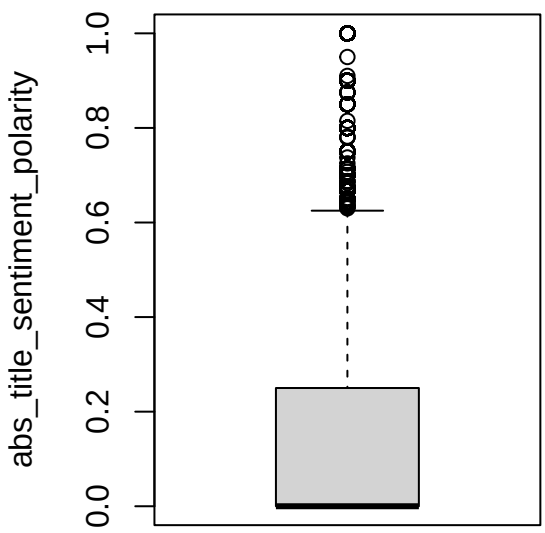

```
##
## ====================================
## Variable: title_sentiment_polarity
## ====================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000    -1.000    -0.700    -0.333    -0.132     0.000     0.000     0.071
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     0.136     0.450     0.500     1.000     1.000 19418.000    50.485
```






```
##
## ===================================
## Variable: abs_title_sentiment_polarity
## ===================================
##         n       min    p01.1%    p05.5%   p10.10%    Q1.25%   mediana     media
## 38463.000     0.000     0.000     0.000     0.000     0.000     0.000     0.155
##    Q3.75%   p90.90%   p95.95%   p99.99%       max     ceros pct_ceros
##     0.250     0.500     0.600     1.000     1.000 19418.000    50.485
```





El método de categorización utilizado es una modificación del método de cuantiles. Es decir, los cortes utilizados si son unos cuantiles de su distirbución, pero no se han seleccionado para equilibrar los niveles resultantes, sino para dividir cada variable según valores "esperados" o "normales" y valores relativamente extremos.

Los cuantiles seleccionados son el Q1 del 25% y el Q3 del 75%, por lo que se han creado 3 niveles iniciales en cada variable, los cuales representan los niveles `bajo`, `medio`, `alto` (con especificación de nombre adecuada en cada caso). De esta manera fijamos un nivel "medio" o "normal" que contiene el 50% de la distribución y los otros dos niveles "extremos" que contienen los valores alejados de ese 50% en ambos sentidos, por un lado los valores pequeños y por otro los grandes.

Este es el procedimiento incial que se siguió, sin embargo gracias al estudio preliminar de sus distribuciones, de detectó que algunas variables necesitaban niveles más específicos, por ejemplo, por la gran presencia de zeros. Por lo tanto, en estos casos ds establecieron los cortes manualmente.

En conclusión, se siguió el proceso mencionado y se revisó variable por variable aplicando correcciones manuales donde fuera necesario.

A continuación se muestran la proporciones de cada clase y estas condicionadas a la variable objetivo:

```
##
## ========================================
```

```
## FRECUENCIAS DE NIVELES
```

```
## ========================================
```

```
##
## ======================================
## Variable: channel
## ======================================
##
##      business entertainment     lifestyle         other        socmed
##          6235          6856          2077          5491          2311
##          tech         world
##          7325          8168
##
##                muy_baja baja media alta
##   business          1980 2864   789  602
##   entertainment     2907 2624   555  770
##   lifestyle          475  984   276  342
##   other             1296 2064   810 1321
##   socmed             242 1203   468  398
##   tech              1546 3720  1120  939
##   world             3650 3311   632  575
##
## Porcentajes por fila:
##
##                muy_baja  baja media  alta
##   business         31.76 45.93 12.65  9.66
##   entertainment    42.40 38.27  8.10 11.23
##   lifestyle        22.87 47.38 13.29 16.47
##   other            23.60 37.59 14.75 24.06
##   socmed           10.47 52.06 20.25 17.22
##   tech             21.11 50.78 15.29 12.82
##   world            44.69 40.54  7.74  7.04
##
## ======================================
## Variable: is_weekend
## ======================================
##
##     0     1
## 33437  5026
##
##     muy_baja  baja media  alta
##   0    11425 14181  3718  4113
##   1      671  2589   932   834
##
## Porcentajes por fila:
##
##     muy_baja  baja media  alta
##   0    34.17 42.41 11.12 12.30
##   1    13.35 51.51 18.54 16.59
##
## ======================================
## Variable: n_tokens_title_cat
## ======================================
##
## corto medio largo
## 13356 18994  6113
##
```

```
##         muy_baja baja media alta
##   corto     3905 5879  1739 1833
##   medio     6098 8299  2257 2340
##   largo     2093 2592   654  774
##
## Porcentajes por fila:
##
##         muy_baja  baja media  alta
##   corto    29.24 44.02 13.02 13.72
##   medio    32.10 43.69 11.88 12.32
##   largo    34.24 42.40 10.70 12.66
##
## ========================================
## Variable: n_tokens_content_cat
## ========================================
##
## corto medio largo
##  9618 19245  9600
##
##         muy_baja baja media alta
##   corto     3030 4001  1166 1421
##   medio     6358 8459  2212 2216
##   largo     2708 4310  1272 1310
##
## Porcentajes por fila:
##
##         muy_baja  baja media  alta
##   corto    31.50 41.60 12.12 14.77
##   medio    33.04 43.95 11.49 11.51
##   largo    28.21 44.90 13.25 13.65
##
## ========================================
## Variable: num_hrefs_cat
## ========================================
##
## pocos_ninguno     moderados        muchos
##         12689         16740          9034
##
##                 muy_baja baja media alta
##   pocos_ninguno     4363 5407  1425 1494
##   moderados         5546 7441  1984 1769
##   muchos            2187 3922  1241 1684
##
## Porcentajes por fila:
##
##                 muy_baja  baja media  alta
##   pocos_ninguno    34.38 42.61 11.23 11.77
##   moderados        33.13 44.45 11.85 10.57
##   muchos           24.21 43.41 13.74 18.64
##
## ========================================
## Variable: num_imgs_cat
## ========================================
##
```

```
## sin_imagenes          una       varias       muchas
##         6170        18047         4828         9418
##
##                muy_baja baja media alta
##   sin_imagenes     1973 2439   754 1004
##   una              6406 7970  2016 1655
##   varias           1441 2255   591  541
##   muchas           2276 4106  1289 1747
##
## Porcentajes por fila:
##
##                muy_baja  baja media  alta
##   sin_imagenes    31.98 39.53 12.22 16.27
##   una             35.50 44.16 11.17  9.17
##   varias          29.85 46.71 12.24 11.21
##   muchas          24.17 43.60 13.69 18.55
##
## ========================================
## Variable: num_videos_cat
## ========================================
##
## sin_videos        uno     varios
##      24661       8718       5084
##
##              muy_baja  baja media  alta
##   sin_videos     7930 10965  2997  2769
##   uno            2699  3624  1082  1313
##   varios         1467  2181   571   865
##
## Porcentajes por fila:
##
##              muy_baja  baja media  alta
##   sin_videos    32.16 44.46 12.15 11.23
##   uno           30.96 41.57 12.41 15.06
##   varios        28.86 42.90 11.23 17.01
##
## ========================================
## Variable: kw_avg_avg_cat
## ========================================
##
##  baja media  alta
##  9616 19231  9616
##
##         muy_baja baja media alta
##   baja      4155 4025   808  628
##   media     5918 8923  2308 2082
##   alta      2023 3822  1534 2237
##
## Porcentajes por fila:
##
##         muy_baja  baja media  alta
##   baja     43.21 41.86  8.40  6.53
##   media    30.77 46.40 12.00 10.83
##   alta     21.04 39.75 15.95 23.26
```

```
##
## ======================================
## Variable: global_subjectivity_cat
## ======================================
##
##   objetiva intermedia  subjetiva
##       9616      19231       9616
##
##              muy_baja baja media alta
##   objetiva       3667 4146   962  841
##   intermedia     5876 8531  2378 2446
##   subjetiva      2553 4093  1310 1660
##
## Porcentajes por fila:
##
##              muy_baja  baja media  alta
##   objetiva      38.13 43.12 10.00  8.75
##   intermedia    30.55 44.36 12.37 12.72
##   subjetiva     26.55 42.56 13.62 17.26
##
## ======================================
## Variable: avg_positive_polarity_cat
## ======================================
##
## baja_nula     media      alta
##      9616     19231      9616
##
##             muy_baja baja media alta
##   baja_nula     3357 4150  1065 1044
##   media         5875 8567  2397 2392
##   alta          2864 4053  1188 1511
##
## Porcentajes por fila:
##
##             muy_baja  baja media  alta
##   baja_nula    34.91 43.16 11.08 10.86
##   media        30.55 44.55 12.46 12.44
##   alta         29.78 42.15 12.35 15.71
##
## ======================================
## Variable: avg_negative_polarity_cat
## ======================================
##
## leve_nula     media      alta
##      9616     19231      9616
##
##             muy_baja baja media alta
##   leve_nula     3030 4375  1164 1047
##   media         6056 8463  2323 2389
##   alta          3010 3932  1163 1511
##
## Porcentajes por fila:
##
##             muy_baja  baja media  alta
```

```
##   leve_nula    31.51 45.50 12.10 10.89
##   media        31.49 44.01 12.08 12.42
##   alta         31.30 40.89 12.09 15.71
##
## ========================================
## Variable: title_subjectivity_cat
## ========================================
##
##          objetivo     algo_subjetivo subjetividad_media          subjetivo
##             17553               5088              10565               5257
##
##                      muy_baja baja media alta
##   objetivo               5677 7703  2099 2074
##   algo_subjetivo         1534 2263   635  656
##   subjetividad_media     3385 4595  1247 1338
##   subjetivo              1500 2209   669  879
##
## Porcentajes por fila:
##
##                      muy_baja  baja media  alta
##   objetivo              32.34 43.88 11.96 11.82
##   algo_subjetivo        30.15 44.48 12.48 12.89
##   subjetividad_media    32.04 43.49 11.80 12.66
##   subjetivo             28.53 42.02 12.73 16.72
##
## ========================================
## Variable: title_sentiment_polarity_cat
## ========================================
##
## negativo   neutro positivo
##     5576    19418    13469
##
##            muy_baja baja media alta
##   negativo     1972 2321   584  699
##   neutro       6179 8569  2323 2347
##   positivo     3945 5880  1743 1901
##
## Porcentajes por fila:
##
##            muy_baja  baja media  alta
##   negativo    35.37 41.62 10.47 12.54
##   neutro      31.82 44.13 11.96 12.09
##   positivo    29.29 43.66 12.94 14.11
##
## ========================================
## Variable: abs_title_sentiment_polarity_cat
## ========================================
##
##   sin_intensidad  intensidad_baja intensidad_media  intensidad_alta
##            19418             4318             9820             4907
##
##                    muy_baja baja media alta
##   sin_intensidad       6179 8569  2323 2347
##   intensidad_baja      1466 1787   519  546
```

```
##   intensidad_media     3107 4313  1168 1232
##   intensidad_alta      1344 2101   640  822
##
## Porcentajes por fila:
##
##                    muy_baja  baja media  alta
##   sin_intensidad      31.82 44.13 11.96 12.09
##   intensidad_baja     33.95 41.38 12.02 12.64
##   intensidad_media    31.64 43.92 11.89 12.55
##   intensidad_alta     27.39 42.82 13.04 16.75
```

2.4 Selección automática de variables mediante Markov Blanket

Aprovechando el contexto de redes bayesianas en el que nos encontramos, se ha decidido utilizar el método de Markov Blanket para realizar una segunda selección de variables. Como ya tenemos las 14 variables candidatas discretizadas, generaremos DAGs con estructura completamente libre que nos muestren qué variables són realmente necesarias para nuestro problema de investigación.

Consideramos esta sección realmente importante porque nos permite identificar qué variables aportan información para nuestro problema de investigación, pero no de una manera aislada, sino una vez consideradas las demás, y por tanto nos ayudará a crear una base de datos más parsimoniosa.

Para aumentar la estabilidad del proceso, se empleó un procedimiento de bootstrap no paramétrico. En cada repetición se generó una muestra bootstrap de los casos de la base de datos, se aprendió una red bayesiana mediante el algoritmo hc y se extrajo el Markov Blanket de popularidad. Posteriormente, se contabilizó cuántas veces aparecía cada variable dentro del Markov Blanket a lo largo de las repeticiones. Este procedimiento se realizó utilizando los criterios de puntuación para el aprendizaje del DAG tanto BIC como AIC.

Finalmente, se conservaron aquellas variables que aparecieron al menos una vez dentro del Markov Blanket de popularidad, y se descartaron aquellas que no aparecieron en ninguna repetición. Con ello se obtuvo una base de datos reducida de 5 variables, cuando se aplicó el criterio BIC, mientras que el criterio AIC determinó que todas las variables condidatas eran necesarias, por lo que la llamamos base de datos completa.

El número de muestras bootstrap generadas fue 100, este valor fue rigurosamente seleccionado: suficientemente alto como para obtener robustez y estabilidad, pero a su vez no demasiado alto para no caer en posible selección de todas las variables por azar, ya que nuestro criterio de almenos una aparición es muy laxo.

A continuación se muestran los resultados de esta sección:

Table 2: Resumen de apariciones en el Markov Blanket con criterio BIC

variable	apariciones	aparece
channel	100	TRUE
is_weekend	100	TRUE
kw_avg_avg_cat	98	TRUE
num_hrefs_cat	82	TRUE
n_tokens_content_cat	17	TRUE
abs_title_sentiment_polarity_cat	0	FALSE
avg_negative_polarity_cat	0	FALSE
avg_positive_polarity_cat	0	FALSE
global_subjectivity_cat	0	FALSE
n_tokens_title_cat	0	FALSE
num_imgs_cat	0	FALSE
num_videos_cat	0	FALSE
title_sentiment_polarity_cat	0	FALSE
title_subjectivity_cat	0	FALSE

Table 3: Variables seleccionadas por Markov Blanket con criterio BIC

variable
channel
is_weekend
n_tokens_content_cat
num_hrefs_cat
kw_avg_avg_cat

Table 4: Resumen de apariciones en el Markov Blanket con criterio AIC

variable	apariciones	aparece
channel	100	TRUE
is_weekend	100	TRUE
kw_avg_avg_cat	100	TRUE
title_subjectivity_cat	89	TRUE
abs_title_sentiment_polarity_cat	84	TRUE
num_videos_cat	83	TRUE
title_sentiment_polarity_cat	80	TRUE
n_tokens_content_cat	74	TRUE
global_subjectivity_cat	64	TRUE
avg_negative_polarity_cat	41	TRUE
n_tokens_title_cat	35	TRUE
num_imgs_cat	30	TRUE
num_hrefs_cat	22	TRUE
avg_positive_polarity_cat	14	TRUE

Table 5: Variables seleccionadas por Markov Blanket con criterio AIC

variable
channel
is_weekend
n_tokens_title_cat
n_tokens_content_cat
num_hrefs_cat
num_imgs_cat
num_videos_cat
kw_avg_avg_cat
global_subjectivity_cat
avg_positive_polarity_cat
avg_negative_polarity_cat
title_subjectivity_cat
title_sentiment_polarity_cat
abs_title_sentiment_polarity_cat

2.5 Base de datos final

En conclusión, salimos de esta sección con dos bases de datos preparadas, ambas utilizadas posteriormente en el análisis:

- `datos_reducida` que cuenta con las variables: `popularidad`, `channel`, `is_weekend`, `n_tokens_content_cat`, `num_hrefs_cat`,`kw_avg_avg_cat`.
- `datos_completa` que cuenta con las variables: `popularidad`, `channel`, `is_weekend`, `n_tokens_title_cat`, `n_tokens_content_cat`, `num_hrefs_cat`, `num_imgs_cat`, `num_videos_cat`, `kw_avg_avg_cat`, `global_subjectivity_cat`, `avg_positive_polarity_cat`, `avg_negative_polarity_cat`, `title_subjectivity_cat`, `title_sentiment_polarity_cat`, `abs_title_sentiment_polarity_cat`.

```
##
## ========================================

## BASE DE DATOS REDUCIDA

## ========================================

## 'data.frame':    38463 obs. of  6 variables:
##  $ popularidad         : Ord.factor w/ 4 levels "muy_baja"<"baja"<..: 1 1 2 2 1 1 1 1 3 1 ...
##  $ channel             : Factor w/ 7 levels "business","entertainment",..: 2 1 1 2 6 6 3 6 6 7 ...
##  $ is_weekend          : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
##  $ n_tokens_content_cat: Factor w/ 3 levels "corto","medio",..: 1 1 1 2 3 2 3 3 1 1 ...
##  $ num_hrefs_cat       : Factor w/ 3 levels "pocos_ninguno",..: 1 1 1 2 3 1 3 3 1 1 ...
##  $ kw_avg_avg_cat      : Factor w/ 3 levels "baja","media",..: 1 1 1 1 1 1 1 1 1 1 ...

##
## ========================================

## BASE DE DATOS COMPLETA
```

```
## ========================================

## 'data.frame':    38463 obs. of  15 variables:
##  $ popularidad                    : Factor w/ 4 levels "muy_baja","baja",..: 1 1 2 2 1 1 1 1 3 1 ..
##  $ channel                        : Factor w/ 7 levels "business","entertainment",..: 2 1 1 2 6 6 3
##  $ is_weekend                     : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
##  $ n_tokens_title_cat             : Factor w/ 3 levels "corto","medio",..: 2 1 1 1 3 2 1 2 2 2 ...
##  $ n_tokens_content_cat           : Factor w/ 3 levels "corto","medio",..: 1 1 1 2 3 2 3 3 1 1 ...
##  $ num_hrefs_cat                  : Factor w/ 3 levels "pocos_ninguno",..: 1 1 1 2 3 1 3 3 1 1 ...
##  $ num_imgs_cat                   : Factor w/ 4 levels "sin_imagenes",..: 2 2 2 2 4 1 4 4 1 2 ...
##  $ num_videos_cat                 : Factor w/ 3 levels "sin_videos","uno",..: 1 1 1 1 1 1 1 1 1 2 .
##  $ kw_avg_avg_cat                 : Factor w/ 3 levels "baja","media",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ global_subjectivity_cat        : Factor w/ 3 levels "objetiva","intermedia",..: 3 1 3 2 3 2 3 3 3
##  $ avg_positive_polarity_cat      : Factor w/ 3 levels "baja_nula","media",..: 2 1 3 2 2 2 2 3 3 1
##  $ avg_negative_polarity_cat      : Factor w/ 3 levels "leve_nula","media",..: 3 1 3 3 2 2 2 2 1 2
##  $ title_subjectivity_cat         : Factor w/ 4 levels "objetivo","algo_subjetivo",..: 3 1 1 1 3 3 1
##  $ title_sentiment_polarity_cat   : Factor w/ 3 levels "negativo","neutro",..: 1 2 2 2 3 3 2 3 2 2
##  $ abs_title_sentiment_polarity_cat: Factor w/ 4 levels "sin_intensidad",..: 3 1 1 1 3 3 1 4 1 1 ...
```

3 Análisis descriptivo

Antes de construir los modelos, se realiza un análisis descriptivo de la base de datos ya preprocesada. El objetivo de este apartado es conocer cómo se distribuye la variable respuesta `popularidad` y estudiar de forma inicial las variables predictoras que forman parte de la base reducida.

Este análisis es útil porque permite comprobar si las clases de popularidad están equilibradas y observar si algunas variables presentan diferencias entre artículos de baja, media o alta popularidad. Estas relaciones se interpretan únicamente de forma descriptiva, es decir, como asociaciones observadas en los datos, no como relaciones causales.

3.1 Distribución de la variable objetivo

La variable objetivo del estudio es `popularidad`, que clasifica los artículos en cuatro niveles ordenados: `muy_baja`, `baja`, `media` y `alta`.

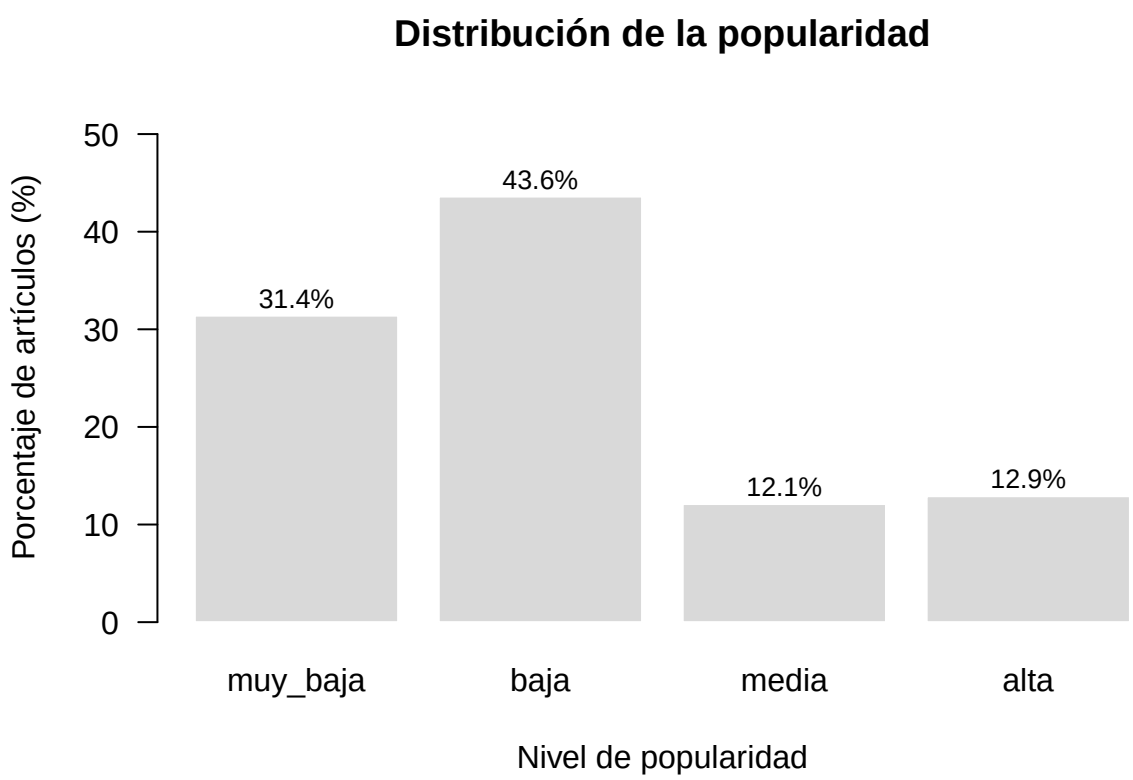
Table 6: Distribución de la variable objetivo popularidad.

Nivel de popularidad	Frecuencia	Porcentaje (%)
muy_baja	12096	31.45
baja	16770	43.60
media	4650	12.09
alta	4947	12.86

Nota: La variable popularidad es ordinal, por lo que sus niveles tienen un orden natural de menor a mayor difusión.

La tabla muestra que la variable `popularidad` no está distribuida de forma equilibrada. La categoría más frecuente es `baja`, que representa el 43,60% de los artículos, seguida de `muy_baja`, con un 31,45%. En cambio, las categorías `media` y `alta` tienen porcentajes bastante menores, alrededor del 12% y 13% respectivamente. Esto indica que la mayoría de artículos se concentran en niveles bajos de popularidad, mientras que solo una parte más reducida alcanza una popularidad media o alta.

Este desbalance es importante porque puede influir en el rendimiento de los modelos. Por este motivo, posteriormente será necesario evaluar los resultados con métricas que tengan en cuenta esta diferencia entre clases.



La distribución de `popularidad` muestra que las categorías no tienen el mismo peso dentro de la base de datos. Las clases de menor popularidad concentran una parte importante de los artículos, mientras que las categorías de popularidad media y alta son menos frecuentes.

Esto es relevante para la modelización, ya que un modelo podría obtener un buen porcentaje de acierto simplemente clasificando bien las clases mayoritarias. Por este motivo, en la evaluación posterior no se utiliza únicamente el `Accuracy`, sino también métricas como `Balanced Accuracy`, `MAE` y `AMAE`, que permiten valorar mejor el rendimiento cuando hay desbalance entre clases y cuando la variable respuesta es ordinal.

3.2 Variables de la base reducida

Tras el proceso de selección de variables mediante Markov Blanket, se obtiene una base reducida formada por las variables más relevantes bajo el criterio BIC. Estas variables son las que se emplean en el modelo principal.

Table 7: Variables incluidas en la base reducida.

Variable	Descripción
channel	Canal temático del artículo.
is_weekend	Indica si el artículo fue publicado en fin de semana.
n_tokens_content_cat	Longitud categorizada del contenido del artículo.
num_hrefs_cat	Número categorizado de enlaces del artículo.
kw_avg_avg_cat	Popularidad histórica media de las palabras clave categorizada.

Nota: La base reducida se utiliza como conjunto principal de predictoras por ser más simple e interpretable.

La tabla anterior resume las variables que forman parte de la base reducida y la información que aporta

cada una. Se observa que estas variables recogen aspectos distintos de los artículos: el tema de publicación, el momento en que se publica, la longitud del contenido, el número de enlaces y la popularidad histórica de las palabras clave.

Por tanto, aunque la base reducida contiene pocas variables, estas permiten representar diferentes dimensiones del artículo. Esto facilita la interpretación del modelo, ya que cada variable tiene un significado claro y puede relacionarse de forma sencilla con la popularidad.

3.3 Distribución de las variables predictoras

A continuación se analiza cómo se distribuyen las variables de la base reducida. Para cada variable se muestra la frecuencia de sus categorías y el porcentaje que representa cada una sobre el total de artículos.

Table 8: Distribución de las variables predictoras de la base reducida.

Variable	Categoría	Frecuencia	Porcentaje (%)
channel	business	6235	16.21
channel	entertainment	6856	17.82
channel	lifestyle	2077	5.40
channel	other	5491	14.28
channel	socmed	2311	6.01
channel	tech	7325	19.04
channel	world	8168	21.24
is_weekend	0	33437	86.93
is_weekend	1	5026	13.07
n_tokens_content_cat	corto	9618	25.01
n_tokens_content_cat	medio	19245	50.04
n_tokens_content_cat	largo	9600	24.96
num_hrefs_cat	pocos_ninguno	12689	32.99
num_hrefs_cat	moderados	16740	43.52
num_hrefs_cat	muchos	9034	23.49
kw_avg_avg_cat	baja	9616	25.00
kw_avg_avg_cat	media	19231	50.00
kw_avg_avg_cat	alta	9616	25.00

Nota: Los porcentajes se calculan respecto al total de artículos de la base reducida.

La tabla muestra la distribución de las variables que forman parte de la base reducida. En primer lugar, se observa que la variable `channel` está repartida entre varios canales, aunque los más frecuentes son `world`, `tech` y `entertainment`. Esto indica que la base no está formada por un único tipo de contenido, sino que incluye noticias de temáticas diferentes.

También se observa que la mayoría de artículos no se publican en fin de semana, ya que `is_weekend = 0` representa una proporción claramente superior a `is_weekend = 1`. En cuanto a la longitud del contenido, la categoría más frecuente es `medio`, mientras que los artículos cortos y largos aparecen en proporciones similares. Respecto al número de enlaces, predominan las categorías con un número moderado o bajo de hipervínculos.

En conjunto, esta tabla permite entender cómo están distribuidas las principales variables explicativas antes de analizar su relación con la popularidad. Además, ayuda a detectar posibles desequilibrios dentro de las categorías, algo importante porque las categorías con mayor frecuencia pueden tener más influencia en el ajuste de los modelos posteriores.

3.4 Relación descriptiva con la popularidad

Para estudiar de forma inicial la relación entre las predictoras y la variable objetivo, se calcula el porcentaje de artículos de popularidad `muy_baja` y `alta` dentro de cada categoría de las variables predictoras.

Se muestran estas dos categorías porque representan los extremos de la variable respuesta. Así, resulta más fácil observar qué niveles de cada variable se asocian con artículos menos populares o más populares.

Table 9: Relación descriptiva con la popularidad: canal y fin de semana.

Variable	Categoría	N	Muy baja (%)	Alta (%)
channel	business	6235	31.76	9.66
channel	entertainment	6856	42.40	11.23
channel	lifestyle	2077	22.87	16.47
channel	other	5491	23.60	24.06
channel	socmed	2311	10.47	17.22
channel	tech	7325	21.11	12.82
channel	world	8168	44.69	7.04
is_weekend	0	33437	34.17	12.30
is_weekend	1	5026	13.35	16.59

Table 10: Relación descriptiva con la popularidad: variables categorizadas.

Variable	Categoría	N	Muy baja (%)	Alta (%)
n_tokens_content_cat	corto	9618	31.50	14.77
n_tokens_content_cat	medio	19245	33.04	11.51
n_tokens_content_cat	largo	9600	28.21	13.65
num_hrefs_cat	pocos_ninguno	12689	34.38	11.77
num_hrefs_cat	moderados	16740	33.13	10.57
num_hrefs_cat	muchos	9034	24.21	18.64
kw_avg_avg_cat	baja	9616	43.21	6.53
kw_avg_avg_cat	media	19231	30.77	10.83
kw_avg_avg_cat	alta	9616	21.04	23.26

En resumen, las tablas muestran que la popularidad no se distribuye igual en todas las categorías de las variables. Las diferencias más claras aparecen en `channel` e `is_weekend`. Algunos canales, como `world` y `entertainment`, tienen más artículos con popularidad `muy_baja`, mientras que otros, como `other`, `socmed` y `lifestyle`, presentan una mayor proporción de artículos con popularidad `alta`.

Además, los artículos publicados en fin de semana parecen tener menor presencia de popularidad `muy_baja` y mayor presencia de popularidad `alta`. Por tanto, de forma descriptiva, estas variables parecen aportar información útil para explicar diferencias en la difusión de los artículos.

3.5 Conclusión del análisis descriptivo

En resumen, el análisis descriptivo muestra que la variable `popularidad` presenta cierto desbalance entre sus categorías, con mayor presencia de artículos en los niveles bajos de popularidad. Esto justifica el uso de métricas de evaluación que tengan en cuenta el desbalance y el orden de las clases.

No obstante, este análisis es únicamente exploratorio. Las diferencias observadas no implican causalidad, sino asociaciones presentes en los datos. En los siguientes apartados, estas variables se analizan de forma conjunta mediante modelos bayesianos de clasificación.

4 Selección de modelos

Con la intención de proporcionar un modelo adecuado para nuestro problema de investigación, se decidió entrenar, validar y comparar diferentes propuestas, considerando tanto la estructura del clasificador como el criterio de predicción y el conjunto de variables predictoras utilizado.

4.1 Modelos propuestos

Se plantearon tres estructuras de clasificadores:

- **Naive Bayes**: se considera como modelo inicial por su sencillez, ya que asume independencia condicional entre las variables predictoras dada la variable objetivo.
- **Tree-Augmented Naive Bayes**: se propone como complementario del Naive Bayes, con el objetivo de relajar parcialmente el supuesto de independencia condicional entre predictoras.
- **Modelo tipo Prognosi**: se plantea como un clasificador acorde con la lógica temporal del problema, ya que las variables predictoras representan características intrínsecas de los artículos, observables antes de que estos sean leídos y compartidos. Por ello, se restringe la estructura del modelo para evitar arcos desde `popularidad` hacia las variables predictoras.

Además, se consideraron dos criterios para convertir las probabilidades posteriores en clases predichas:

- **Criterio Ord-MAP**: seleccionado por ser adecuado para una variable respuesta ordinal.
- **Criterio MAP**: incluido también para comparar si la incorporación del orden mediante Ord-MAP mejora el rendimiento predictivo.

Los tres clasificadores se validaron utilizando ambos criterios de predicción, dando lugar a 6 métodos de actuación posibles.

Además, debemos recordar que trabajamos con dos conjuntos de predictoras seleccioandas, prodecentes de:

- `datos_reducida`
- `datos_completa`

Por tanto, las 6 combinaciones de métodos se aplicaron en ambos conjuntos de datos, obteniéndose un total de 12 combinaciones posibles, que deberan ser comparadas con prudencia.

4.2 Metodología de evaluación

Validación

Como mecanismo de validación se empleará un k-fold cross-validation estratificado, dividiendo así la base de datos en 10 folds que mantienen la misma proporción de clases de `populaidad`. Esta decisión fue derivada de la preocupación por el desbalance de clases de la variable objetivo, de esta manera evitamos en puedan generarse folds donde alguna clase no aparezca o sea tan minoritaria que complique el análisis:

```
##
## ========================================
```

```
## PROPORCIÓN DE LOS FOLDS
```

```
## ======================================
```

```
##
## folds muy_baja baja media alta
##    1      1210 1677   465  495
##    2      1210 1677   465  495
##    3      1210 1677   465  495
##    4      1210 1677   465  495
##    5      1210 1677   465  495
##    6      1210 1677   465  495
##    7      1209 1677   465  495
##    8      1209 1677   465  494
##    9      1209 1677   465  494
##    10     1209 1677   465  494
```

```
##
## folds muy_baja  baja media  alta
##    1     0.315 0.436 0.121 0.129
##    2     0.315 0.436 0.121 0.129
##    3     0.315 0.436 0.121 0.129
##    4     0.315 0.436 0.121 0.129
##    5     0.315 0.436 0.121 0.129
##    6     0.315 0.436 0.121 0.129
##    7     0.314 0.436 0.121 0.129
##    8     0.314 0.436 0.121 0.128
##    9     0.314 0.436 0.121 0.128
##    10    0.314 0.436 0.121 0.128
```

Estos mismos 10 folds serán utilizados en cada proceso de entrenamiento, es decir, todas las propuestas serán entrenadas y validadas en los mismos datos, de esta manera optendremos muestras apareadas de las métricas calculadas y estas propuestas podrán ser comparadas justamente.

Métricas

Para cada modelo se calcularon diferentes métricas de evaluación:

- **Accuracy**: como métrica general, mide la proporción global de observaciones correctamente clasificadas.
- **Balanced Accuracy**: complementaria al general Accuracy, debido al desbalance de clases, ya que evita que el rendimiento del modelo quede dominado por las categorías más frecuentes. En nuestro caso multi-clase, esta métrica no es más que un average Recall que generaliza la idea de promediar el Recall de la clase positiva y negativa de un problema binario, en nuestro caso promediando todas las clases. Igualmente, hemos decidido llamarlo Balanced Accuracy por interpretabilidad.
- **MAE**: adecuada para el problema ordinal ya que mide el error absoluto medio entre la clase observada y la clase predicha, considerando el orden de las categorías de popularidad, y de esta manera no se otorga el mismo peso a errores ntre dos clases consecutivas que entre categorías alejadas.
- **AMAE**: adecuada para nuestro problema que es ordinal y además de clases desbalanceadas. Calcula el MAE para cada clase observada y después promedia estos errores por clase, de esta manera evita que el rendimiento del modelo quede dominado por las categorías más frecuentes.
- **Matriz de confusión general**: permite analizar con mayor detalle el comportamiento del modelo y así podemos ver en que clases se producen los errores.

La métrica que será utilizada para comparar los modelos será AMAE, ya que responde perfectamente a nuestras necesidades.

Adicionalmente se calcularon las medias y desviaciones típicas de cada métrica para tener una visión global del funcionamiento de cada propuesta y de su estabilidad. A continuación se presentan dichos resultados:

```
##
## ========================================
```

```
## RESULTADOS BASE REDUCIDA
```

```
## ========================================
```

```
##    modelo criterio           metrica     media desviacion_tipica
## 1      NB  Ord-MAP              AMAE 0.9445136       0.010374768
## 2      NB  Ord-MAP               MAE 0.7069396       0.007135037
## 3      NB  Ord-MAP          Accuracy 0.4352233       0.005887157
## 4      NB  Ord-MAP Balanced_Accuracy 0.2979763       0.005994345
## 5      NB      MAP              AMAE 0.9967786       0.007963637
## 6      NB      MAP               MAE 0.7586778       0.005585427
## 7      NB      MAP          Accuracy 0.4646278       0.003918440
## 8      NB      MAP Balanced_Accuracy 0.3379484       0.004710087
## 9     TAN  Ord-MAP              AMAE 0.9551246       0.008841074
## 10    TAN  Ord-MAP               MAE 0.6867126       0.007237258
## 11    TAN  Ord-MAP          Accuracy 0.4495483       0.005383068
## 12    TAN  Ord-MAP Balanced_Accuracy 0.2993541       0.003921809
## 13    TAN      MAP              AMAE 1.0102572       0.008971359
## 14    TAN      MAP               MAE 0.7192631       0.006835570
## 15    TAN      MAP          Accuracy 0.4744558       0.003881988
## 16    TAN      MAP Balanced_Accuracy 0.3277259       0.003645408
## 17   PROG  Ord-MAP              AMAE 0.9949265       0.005307846
## 18   PROG  Ord-MAP               MAE 0.6838006       0.004613704
## 19   PROG  Ord-MAP          Accuracy 0.4594280       0.004578120
## 20   PROG  Ord-MAP Balanced_Accuracy 0.2843295       0.004024372
## 21   PROG      MAP              AMAE 1.0242248       0.009524117
## 22   PROG      MAP               MAE 0.6972420       0.007054758
## 23   PROG      MAP          Accuracy 0.4746633       0.005575766
## 24   PROG      MAP Balanced_Accuracy 0.3115742       0.004348237
```

```
##
## ========================================
```

```
## RESULTADOS BASE COMPLETA
```

```
## ========================================
```

```
##    modelo criterio           metrica     media desviacion_tipica
## 1      NB  Ord-MAP              AMAE 0.9473775       0.012511769
## 2      NB  Ord-MAP               MAE 0.7570925       0.010085819
## 3      NB  Ord-MAP          Accuracy 0.4377448       0.005111736
## 4      NB  Ord-MAP Balanced_Accuracy 0.3269357       0.004390512
## 5      NB      MAP              AMAE 0.9995176       0.013784676
```

```
## 6      NB      MAP               MAE 0.8122628       0.010298178
## 7      NB      MAP          Accuracy 0.4498079       0.004789674
## 8      NB      MAP Balanced_Accuracy 0.3469348       0.005246734
## 9     TAN  Ord-MAP              AMAE 0.9493089       0.010248301
## 10    TAN  Ord-MAP               MAE 0.6976321       0.008012943
## 11    TAN  Ord-MAP          Accuracy 0.4515506       0.004352964
## 12    TAN  Ord-MAP Balanced_Accuracy 0.3114389       0.004203701
## 13    TAN      MAP              AMAE 1.0060892       0.012273647
## 14    TAN      MAP               MAE 0.7467441       0.006826863
## 15    TAN      MAP          Accuracy 0.4678000       0.002848833
## 16    TAN      MAP Balanced_Accuracy 0.3355936       0.004077404
## 17   PROG  Ord-MAP              AMAE 0.9949265       0.005307846
## 18   PROG  Ord-MAP               MAE 0.6838006       0.004613704
## 19   PROG  Ord-MAP          Accuracy 0.4594280       0.004578120
## 20   PROG  Ord-MAP Balanced_Accuracy 0.2843295       0.004024372
## 21   PROG      MAP              AMAE 1.0242248       0.009524117
## 22   PROG      MAP               MAE 0.6972420       0.007054758
## 23   PROG      MAP          Accuracy 0.4746633       0.005575766
## 24   PROG      MAP Balanced_Accuracy 0.3115742       0.004348237
```

Presentamos también las matrices de confusión globales para cada propuesta en cada conjunto de predictoras:

```
##
## ========================================
```

```
## MATRICES BASE REDUCIDA
```

```
## ========================================
```

```
## $NB_OrdMAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     2701  1823   322   265
##   baja         8582 13177  3564  3491
##   media         723  1548   667   996
##   alta           90   222    97   195
##
## $NB_MAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     5856  4336   796   781
##   baja         5417 10954  3237  3105
##   media           0     0     0     0
##   alta          823  1480   617  1061
##
## $TAN_OrdMAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     3577  2420   406   332
##   baja         8130 13174  3703  3780
##   media         389  1174   540   835
##   alta            0     2     1     0
##
```

```
## $TAN_MAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     6223  4641   874   894
##   baja         5552 11474  3474  3524
##   media           1    31    50    27
##   alta          320   624   252   502
##
## $PROG_OrdMAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     3014  2083   348   275
##   baja         9073 14566  4211  4602
##   media           9   121    91    70
##   alta            0     0     0     0
##
## $PROG_MAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     6317  4830   868   813
##   baja         5764 11862  3706  4082
##   media           6    66    74    48
##   alta            9    12     2     4

##
## ========================================

## MATRICES BASE COMPLETA

## ========================================

## $NB_OrdMAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     4171  2902   483   420
##   baja         6642 11251  3151  2879
##   media         600  1291   463   696
##   alta          683  1326   553   952
##
## $NB_MAP
##           Observada
## Predicha   muy_baja baja media alta
##   muy_baja     5891 4513   822  773
##   baja         4860 9864  2927 2629
##   media           0    0     1    0
##   alta         1345 2393   900 1545
##
## $TAN_OrdMAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     3905  2590   431   397
##   baja         7652 12670  3561  3544
##   media         400  1219   550   763
```

```
##   alta          139   291   108   243
##
## $TAN_MAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     6151  4601   886   901
##   baja         5341 10950  3259  3174
##   media           1    36    46    26
##   alta          603  1183   459   846
##
## $PROG_OrdMAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     3014  2083   348   275
##   baja         9073 14566  4211  4602
##   media           9   121    91    70
##   alta            0     0     0     0
##
## $PROG_MAP
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     6317  4830   868   813
##   baja         5764 11862  3706  4082
##   media           6    66    74    48
##   alta            9    12     2     4
```

Estas matrices son la agregación de las matrices de cada fold, de manera que los valores mostrados son más altos que el total de observaciones de la base de datos, pero nos sirven para indentificar cómo funciona en modelo en cada clase, ya que las propociones son las mismas.

4.3 Comparación de modelos

Recordemos que hemos planteado un total de 12 combinaciones posibles y queremos discernir cual de ellas es de alguna manera óptima. Para ello se compararán sus valores de AMAE, y se escogerá la que presente valores más bajos, ya que esta es una medida de error. El objetivo último es utilizar contrastes de hipótesis adecuados que nos permitan afirmar qué propuestas presentan valores significativamente inferiores de AMAE.

Debido al tipo de validación utilizado contamos con un vector de 10 posiciones para cada propuesta, el cual contiene los valores de AMAE de cada fold. Como comentamos, los mismos folds fueron utilizados en todos los procesos, de manera que nos encontramos frente a comparaciones de muestras apareadas. Los tests empleados son:

- **Friedman**: para test primeramente si existen diferencias globales significativas entre métodos, ya que comparamos más de dos.
- **Shapiro-Wilk**: para testear la Normalidad de las diferencias apareadas dos a dos
- **T-test**: para test cada diferencia apareada y responder a nuestra pregunta de inferioridad significativa, en los casos donde se asume Normalidad (es decir, no se descrata Normalidad)
- **Wilcoxon**: igual que el t-test pero en los casos donde se descarta Normalidad

Todos los contrastes fueron evaluados mediante un 95% de confianza, y los últimos dos fueron aplicados siempre de tipo unilateral, ya que nuestra pregunta no es detectar diferencia sino inferioridad significativa.

Además, se aplicó una correción por multiplicidad de contrastes de tipo **Holm** sobre los p-valores obtenidos. Esta corrección nos permite reducir el riesgo de obtener resultados significativos por azar y mantener nuestra confianza en el umbral deseado.

Estructura de las compraciones

Debido al gran volumen de comparaciones a realizar, se decidió establecer un orden lógico y argumentado que nos permitiera proceder mas detenidamente.

La idea general es la siguiente: como las 12 propuestas provienen de 2 conjuntos de predictoras diferentes, primero se determinará la preferida para cada conjunto y posteriormente se enfrentarán estas dos para determinar la ganadora.

Dentro de cada conjunto, `datos_reducida` y `datos_completa`, primeramente se aplicó el test de Friedman para descartar igualdad global, sus hipotesis son las siguientes:

H_0: todos los modelos presentan el mismo rendimiento en términos de AMAE

H_1: al menos uno de los modelos presenta un rendimiento significativamente diferente en términos de AMAE

Los resultados fueron los siguientes:

```
##
## ========================================

## Friedman - Base reducida

## ========================================

##
##  Friedman rank sum test
##
## data:  as.matrix(AMAE_comparacion)
## Friedman chi-squared = 47.771, df = 5, p-value = 3.955e-09

##
## ========================================

## Friedman - Base completa

## ========================================

##
##  Friedman rank sum test
##
## data:  as.matrix(AMAE_comparacion)
## Friedman chi-squared = 44.686, df = 5, p-value = 1.681e-08
```

Ambos significativos por lo que procedemos al siguiente paso.

A continuación, se examinaron los promedios de AMAE de los 6 modelos empleados y se seleccionó como potencial preferido aquel con valor inferior. Posteriormente se procedió a contrastar este candidato contra el resto de propuestas, para así confirmar si esta preseleccionada será la ganadora abalada por criterios estadísticos.

Como podemos observar, el modelo candidato preseleccionado en ambos conjuntos es Naive Bayes con criterio de predicción Ord-MAP:

```
##
## ======================================
```

```
## RANKING AMAE - Base reducida
```

```
## ======================================
```

```
##        metodo AMAE_medio desviacion_tipica
## 1   NB_ORDMAP  0.9445136       0.010374768
## 2  TAN_ORDMAP  0.9551246       0.008841074
## 3 PROG_ORDMAP  0.9949265       0.005307846
## 4      NB_MAP  0.9967786       0.007963637
## 5     TAN_MAP  1.0102572       0.008971359
## 6    PROG_MAP  1.0242248       0.009524117
```

```
##
## ======================================
```

```
## RANKING AMAE - Base completa
```

```
## ======================================
```

```
##                  metodo AMAE_medio desviacion_tipica
## NB_ORDMAP     NB_ORDMAP  0.9473775       0.012511769
## TAN_ORDMAP   TAN_ORDMAP  0.9493089       0.010248301
## PROG_ORDMAP PROG_ORDMAP  0.9949265       0.005307846
## NB_MAP           NB_MAP  0.9995176       0.013784676
## TAN_MAP         TAN_MAP  1.0060892       0.012273647
## PROG_MAP       PROG_MAP  1.0242248       0.009524117
```

El siguiente paso es tomar este modelo y contrastarlo dos a dos contra el resto, primeramente empleando Shapiro-Wilk y posteriormente el test apropiado para cada diferencia. Las hipótesis que testamos en cada test de diferencias son las siguientes:

$$H_0 : AMAE_{candidato} \geq AMAE_{comparado}$$

$$H_1 : AMAE_{candidato} < AMAE_{comparado}$$

A continuación se muestran los resultados para cada conjunto:

Table 11: Comparaciones apareadas unilaterales - Base reducida

modelo_referencia	modelo_comparado	media_referencia	media_comparado	p_shapiro	normalidad	test_aplicado	p_valor	p_valor_ajustado_Holm	significativo
NB_ORDMAP	NB_MAP	0.9445	0.9968	0.1778	Normalidad	t-test apareado unilateral	0e+00	0e+00	TRUE
NB_ORDMAP	TAN_MAP	0.9445	1.0103	0.1830	Normalidad	t-test apareado unilateral	0e+00	0e+00	TRUE
NB_ORDMAP	TAN_ORDMAP	0.9445	0.9551	0.1156	Normalidad	t-test apareado unilateral	7e-04	7e-04	TRUE
NB_ORDMAP	PROG_MAP	0.9445	1.0242	0.3911	Normalidad	t-test apareado unilateral	0e+00	0e+00	TRUE
NB_ORDMAP	PROG_ORDMAP	0.9445	0.9949	0.6287	Normalidad	t-test apareado unilateral	0e+00	0e+00	TRUE

En el caso de `datos_reducida` todos los contrastes salen significativos, de manera que podemos afirmar que el modelo **Naive Bayes con criterio Ord-MAP** es el mejor, según nuestros criterios, para este conjunto de predictoras.

Table 12: Comparaciones apareadas unilaterales - Base completa

modelo_referencia	modelo_comparado	media_referencia	media_comparado	p_shapiro	normalidad	test_aplicado	p_valor	p_valor_ajustado_Holm	significativo
NB_ORDMAP	NB_MAP	0.9474	0.9995	0.7851	Normalidad	t-test apareado unilateral	0.0000	0.0000	TRUE
NB_ORDMAP	TAN_MAP	0.9474	1.0061	0.0328	No normalidad	Wilcoxon apareado unilateral	0.0030	0.0059	TRUE
NB_ORDMAP	TAN_ORDMAP	0.9474	0.9493	0.0568	Normalidad	t-test apareado unilateral	0.2509	0.2509	FALSE
NB_ORDMAP	PROG_MAP	0.9474	1.0242	0.9257	Normalidad	t-test apareado unilateral	0.0000	0.0000	TRUE
NB_ORDMAP	PROG_ORDMAP	0.9474	0.9949	0.5568	Normalidad	t-test apareado unilateral	0.0000	0.0000	TRUE

En el caso de `datos_completa` obtenemos que uno de los test no es significativo, conretamente el que testea nuestro candidato contra el modelo Tree-Augmented Naive Bayes también con criterio Ord-MAP, de manera que no podemos descartar la igualdad entre este y nuestro candidato. Sin embargo, si podemos afirmar que, a excepción de este, nuestro candidato sí obtiene valores de AMAE significativamente inferiores al resto. Por lo tanto, siguiendo un criterio de parsimonia, decidimos seleccionar el modelo **Naive Bayes con criterio Ord-MAP** como clasificado para la selección del modelo principal.

Sin embargo, conservamos el **Tree-Augmented Naive Bayes con criterio Ord-MAP** como modelo secundario.

En este punto solo nos falta contrastar nuestros dos modelos Naive Bayes seleccionados entre si:

```
## AMAEs medios:
## Base reducida: 0.9445136
## Base completa 0.9473775
```

A continuación se presentan los resultados:

```
## Test de Normalidad:

##
##  Shapiro-Wilk normality test
##
## data:  dif_AMAE
## W = 0.75048, p-value = 0.003617

## Test unilateral de diferencias:

##
##  Wilcoxon signed rank exact test
##
## data:  AMAE_reducida and AMAE_completa
## V = 19, p-value = 0.2158
## alternative hypothesis: true location shift is less than 0
```

Se descarta Normalidad y por lo tanto se realiza un test unilateral no paramétrico de Wilcoxon para muestras apareadas, que no resulta significativo, de manera que no tenemos evidencia estadística suficiente para afirmar que el AMAE de la base reducida sea significativamente inferior al de la base completa. Finalmente, siguiendo un criterio de parsimonia, decidimos seleccionar como modelo principal un **Naive Bayes con criterio Ord-MAP utilizando el conjunto reducido de predictoras**

En el código del estudio, el entrenamiento de los modelos y su comparación se hizo de forma consecutiva primero para la base de datos completa y posteriormente para la reducida, ya que esta manera permitia hacer menos modificaicones al código y sobreescribir los objetos que no era necesario conservar. Es decir, primero se entrenan y se comparan los modelos de `base_completa` y después se procede de igual manera para `base_reducida`, finalmente se comparan los modelos obtenidos como óptimos en cada una. Los objetos que fuera necesario guardar para mostrar en el presente informe fueron guardado antes de sobreescribir.

4.4 Modelos finales

Modelo principal: Naive Bayes con criterio Ord-MAP sobre conjunto reducido de predictoras. Este será el modelo utilizado para realizar el estudio de precciones

Modelo secundario: Tree-Augmented Naive Bayes con criterio Ord_MAP sobre conjunto completo de predictoras.

La decisión de incluir un modelo secundario en nuestro estudio se fundamenta en la cracaterística estructural de este, ya que un Tree-Augmented permite relaciones adicionales entre predictoras, lo cual nos permitirá interpretarlas para conocer un poco mejor como interactuan estas para predecir popularidad.

5 Modelo Principal: Naive Bayes con Ord-Map

Cómo hemos comentado, nuestro modelo principal es **Naive Bayes con criterio Ord-MAP sobre conjunto reducido de predictoras**.

Primeramente, para aprender su estructura se utilizó la función `naive.bayes`, seguidamente se aprendieron sus parámetros mediante `bn.fit` con método bayes y además se incorporó un suavizado `iss=1`. Este suavizado actúa evitando que el modelo asigne una probabilidad artificialmente nula a una clase por falta de una combinación de clases predictora-objetivo. Es decir, aunque Naive Bayes puede trabajar con casos no existentes en la base de datos sin dar error, lo que sí puede ocurrir es que otorgue una probabilidad 0 si alguna de las probabilidades condicionadas que intervienen en su cálculo es nula.

El suavizado lo que hace es incorporar una pequeña cantidad de información previa a las frecuencias observadas para así evitar que combinaciones poco frecuentes reciban probabilidad nula.

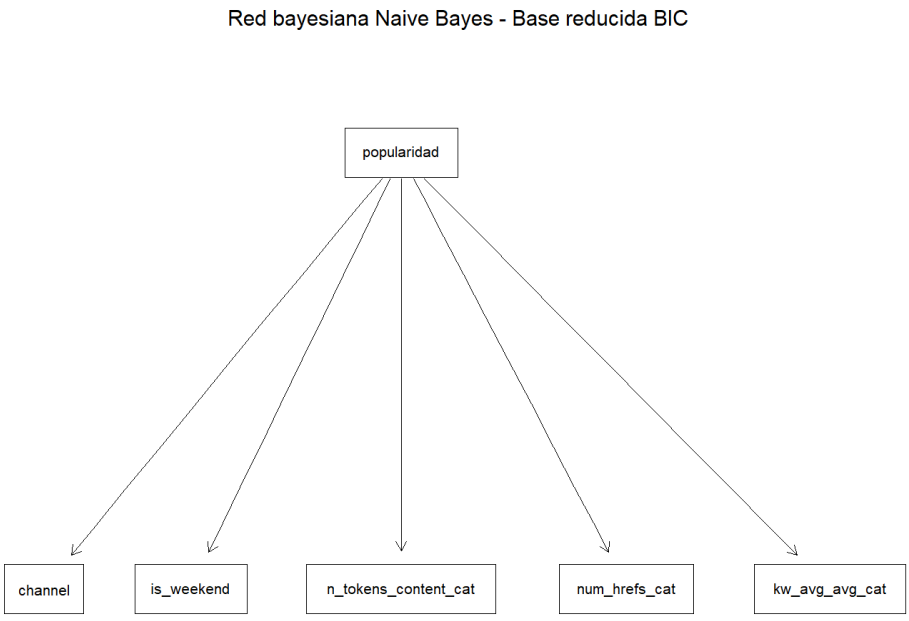
Consideramos esta decisión principalmente por la preocupación que nos generaba el desequilibrio en las clases de `popularidad`, y además porque tenemos una variable objetivo con 4 niveles que al repartirse en las combinaciones con los niveles de las predictoras podemos obtener celdas poco frecuentes.

Aunque la posibilidad de celdas vacías ya se descartó en la comprobación de frecuencias después de la categorización, sí se observaron celdas poco frecuentes en comparación. Además, teniendo en cuenta el proceso de validación mediante folds, aunque estos fueron estratificados, podía aumentar la posibilidad de obtener celdas vacías ya que cada fold de entrenamiento tiene menos datos que la base completa.

Finalmente, se convirtió el objeto de tipo `bnlearn` a uno de tipo `gRain` mediante la función `as.grain` para realizar inferencia.

5.1 Estructura del modelo final

DAG



Su estructura se caracteriza por situar la variable objetivo popularidad como nodo raíz/padre, del cual dependen directamente todas las variables explicativas seleccionadas. Cabe decir que la interpretación estructural del modelo es limitada, ya que el Naive Bayes impone una estructura rígida basada en la independencia condicional entre predictoras dada la clase. Por ello, su interés principal no reside en interpretar relaciones entre variables, sino en obtener una herramienta predictiva sencilla, estable y parsimoniosa.

Aunque este supuesto puede resultar restrictivo, el modelo ha demostrado mejor comportamiento predictivo en la fase de validación respecto a la resta de modelos y presenta una ventaja clara en términos de parsimonia. Por ello, resulta adecuado como modelo principal del estudio.

Apunte: El DAG es la estructura Naive Bayes, pero para el modelo final también hay que tener en cuenta el criterio de clasificación escogido (OrdMAP).

A continuación se muestran sus tablas CTP, que responden a probabilidades del tipo $P(X_j = x|popularidad = y)$, es decir, recogen las probabilidades de cada valor de las variables predictoras condicionado a cada clase de la variable objetivo popularidad.

CTPs

```
##
## ========================================
## popularidad
## ========================================
## muy_baja     baja    media     alta
##   0.3145   0.4360   0.1209   0.1286
##
## ========================================
## channel
## ========================================
##                popularidad
## channel         muy_baja   baja  media   alta
##   business        0.1637 0.1708 0.1697 0.1217
##   entertainment   0.2403 0.1565 0.1194 0.1556
##   lifestyle       0.0393 0.0587 0.0594 0.0691
##   other           0.1071 0.1231 0.1742 0.2670
##   socmed          0.0200 0.0717 0.1006 0.0805
##   tech            0.1278 0.2218 0.2409 0.1898
##   world           0.3017 0.1974 0.1359 0.1162
##
## ========================================
## is_weekend
## ========================================
##           popularidad
## is_weekend muy_baja   baja  media   alta
##          0   0.9445 0.8456 0.7996 0.8314
##          1   0.0555 0.1544 0.2004 0.1686
##
## ========================================
## n_tokens_content_cat
## ========================================
##                      popularidad
## n_tokens_content_cat muy_baja   baja  media   alta
##                corto   0.2505 0.2386 0.2508 0.2872
##                medio   0.5256 0.5044 0.4757 0.4479
##                largo   0.2239 0.2570 0.2736 0.2648
##
```

```
## ======================================
## num_hrefs_cat
## ======================================
##                popularidad
## num_hrefs_cat   muy_baja   baja  media   alta
##   pocos_ninguno   0.3607 0.3224 0.3065 0.3020
##   moderados       0.4585 0.4437 0.4267 0.3576
##   muchos          0.1808 0.2339 0.2669 0.3404
##
## ======================================
## kw_avg_avg_cat
## ======================================
##               popularidad
## kw_avg_avg_cat muy_baja   baja  media   alta
##          baja    0.3435 0.2400 0.1738 0.1270
##          media   0.4892 0.5321 0.4963 0.4209
##          alta    0.1672 0.2279 0.3299 0.4522
```

5.2 Capacidad discriminativa de las variables

Para analizar la capacidad discriminativa de las variables, se estudian las distribuciones condicionadas de cada predictora según los niveles de `popularidad`. Una variable es especialmente informativa cuando sus probabilidades condicionadas cambian claramente entre las categorías de popularidad. Estas variables no deben interpretarse de forma causal, sino como indicadores asociados a distintos niveles de popularidad.

De las probabilidades condicionadas mostradas en la presentación del modelo podemos extraer las siguientes conclusiones sobre el poder predictivo de las variables:

- Variables con alta capacidad discriminativa: Las variables `kw_avg_avg_cat` y `channel` son las más informativas. Las palabras clave de impacto alto y los canales como `socmed` u `other` multiplican su presencia en los niveles de popularidad más altos.
- Indicadores de éxito: Publicar en fin de semana (`is_weekend`) y la inclusión de muchos enlaces (`num_hrefs_cat`) aumentan drásticamente su probabilidad conforme el artículo escala hacia una popularidad media o alta.
- Variables de bajo impacto: La extensión del contenido (`n_tokens_content_cat`) es la variable menos relevante, mostrando una distribución homogénea (alrededor del 50% para la longitud media) de forma transversal en todas las categorías.

Cabe recordar que se trata de probabilidades condicionales evaluadas de forma individual (una a una) y que, en su conjunto, el modelo tiene una estructura matemática más compleja. Por ello, la clase que finalmente asigne no siempre coincidirá con las tendencias que vemos en estas probabilidades aisladas.

Cuantificar la capacidad discriminativa

Para estudiar la capacidad discriminativa de cada variable, ya hemos analizado las tablas de probabilidad condicionada ($P(X \mid \textit{popularidad})$). La idea es que una variable será más discriminativa cuanto más cambie su distribución entre las distintas clases de popularidad.

Lo que hacemos en esta segunda parte, es cuantificarlo, en cada nivel de la variable calculamos la diferencia entre la probabilidad máxima y mínima observada entre las clases de popularidad. Posteriormente, estas diferencias se promedian para obtener una única medida por variable. Por tanto, valores altos nos indican que la variable presenta distribuciones claramente distintas según el nivel de popularidad, mientras que valores bajos indican una distribución más homogénea y, por lo tanto, una menor capacidad discriminativa.

Table 13: Capacidad discriminativa variables

	capacidad_discriminativa_variables
kw_avg_avg_cat	0.2042352
is_weekend	0.1449641
num_hrefs_cat	0.1064008
channel	0.1055718
n_tokens_content_cat	0.0586735

Según los resultados obtenidos, `kw_avg_avg_cat` es la variable con mayor capacidad discriminativa, seguida de `is_weekend`, `num_hrefs_cat`, `channel` y `n_tokens_content_cat`. Sin embargo, tenemos que tener en cuenta que esto no anula directamente el análisis que hemos realizado justo antes, los canales `socmed` u `other` siguen siendo clases positivas, en cambio, complementa el análisis anterior.

5.3 Probabilidades posteriores

En este apartado se realiza inferencia bayesiana para convertir las probabilidades de las CTPs en probabilidades de la fomra $P(popularidad = y|X_j = x)$, es decir, probabilidad estimada por la red bayesiana para cada categoría de la variable objetivo, condicionada a la evidencia introducida. Buscamos poder estudiar en detalle cómo se comporta la distribución de la variable `popularidad` una vez fijada la evidencia de las variables predictoras y así responde ra preguntas del tipo ¿cómo cambia la probabilidad de que una noticia tenga popularidad muy baja, baja, media o alta si sabemos que pertenece a un determinado canal, que se publica en fin de semana o que presenta un cierto nivel de enlaces, imágenes o longitud?

De nuevo, debe tenerse en cuenta que estos resultados se interpretan como asociaciones dentro del modelo ajustado y no cómo relaciones causales.

A continuación se procede a mostrar los resultados para cada variable:

Table 14: Probabilidades a posteriori de channel

variable	nivel	muy_baja	baja	media	alta
channel	business	0.3175606	0.4593376	0.1265465	0.0965552
channel	entertainment	0.4240045	0.3827277	0.0809545	0.1123133
channel	lifestyle	0.2286967	0.4737448	0.1328920	0.1646664
channel	other	0.2360229	0.3758845	0.1475168	0.2405757
channel	socmed	0.1047256	0.5205371	0.2025127	0.1722246
channel	tech	0.2110588	0.5078448	0.1529029	0.1281935
channel	world	0.4468624	0.4053597	0.0773781	0.0703998

Para la variable `channel`, se observan diferencias claras entre canales. Los artículos de `world` y `entertainment` concentran mayor probabilidad en la clase `muy_baja`, mientras que canales como `other`, `socmed` y `lifestyle` desplazan más probabilidad hacia las clases `media` y `alta`. Destaca especialmente `other`, con la mayor probabilidad posterior de popularidad `alta`.

Table 15: Probabilidades a posteriori de res_is_weekend

variable	nivel	muy_baja	baja	media	alta
is_weekend	0	0.3416860	0.4241084	0.1111963	0.1230093
is_weekend	1	0.1335174	0.5150950	0.1854422	0.1659455

Respecto a la variable `is_weekend`, publicar en fin de semana reduce claramente la probabilidad de popularidad `muy_baja` y aumenta la probabilidad de las clases `baja`, `media` y `alta`. Aun así, la clase más probable sigue siendo `baja`, aunque esta variable no determina por sí sola una alta popularidad (ninguna de hecho lo determina por sí sola), sí que desplaza la distribución hacia niveles algo superiores.

Table 16: Probabilidades a posteriori de res_n_tokens_content

variable	nivel	muy_baja	baja	media	alta
n_tokens_content_cat	corto	0.3150321	0.4159851	0.1212355	0.1477474
n_tokens_content_cat	medio	0.3303701	0.4395395	0.1149413	0.1151491
n_tokens_content_cat	largo	0.2820822	0.4489514	0.1325041	0.1364623

La variable `n_tokens_content_cat` muestra diferencias más moderadas. La longitud del contenido no produce cambios tan marcados como otras variables, aunque los artículos cortos y largos presentan una probabilidad algo menor de `muy_baja` y algo mayor de `media` y `alta` respecto a los artículos de longitud media.

Table 17: Probabilidades a posteriori de res_num_hrefs

variable	nivel	muy_baja	baja	media	alta
num_hrefs_cat	pocos_ninguno	0.3438387	0.4261125	0.1123056	0.1177432
num_hrefs_cat	moderados	0.3313007	0.4445003	0.1185211	0.1056779
num_hrefs_cat	muchos	0.2420857	0.4341309	0.1373741	0.1864093

En `num_hrefs_cat`, los artículos con muchos enlaces presentan menor probabilidad de `muy_baja` y mayor probabilidad de `media` y `alta` que los artículos con pocos enlaces o enlaces moderados. Esto sugiere que un mayor número de enlaces está asociado con un desplazamiento hacia niveles superiores de popularidad y que la diferencia entre las clases pocos o ningún enlace y moderados enlaces es pequeña.

Table 18: Probabilidades a posteriori de res_kw_avg_avg

variable	nivel	muy_baja	baja	media	alta
kw_avg_avg_cat	baja	0.4320860	0.4185674	0.0840324	0.0653142
kw_avg_avg_cat	media	0.3077313	0.4639867	0.1200168	0.1082652
kw_avg_avg_cat	alta	0.2103799	0.3974575	0.1595289	0.2326337

Finalmente, `kw_avg_avg_cat` es la variable con el patrón más claro. Cuando su nivel es bajo, el modelo concentra la probabilidad en las clases `muy_baja` y `baja`. En cambio, cuando su nivel media, disminuye la probabilidad de `muy_baja` y aumentan las probabilidades de `baja` , `media` y `alta`. A la vez, cuando pasamos a la clase alta bajan las probabilidades de `muy_baja` y de `baja` y vuelven a aumentar las de `media` y `alta`. Por tanto, valores altos en esta variable se asocian con una mayor probabilidad de popularidad elevada, aunque la clase más probable es `baja`.

En conjunto, las probabilidades posteriores permiten observar que ninguna variable individual garantiza una clase concreta de popularidad, cosa que era de esperar, pero sí modifican la distribución de probabilidades del modelo. Las variables que más desplazan la probabilidad hacia niveles superiores son `kw_avg_avg_cat`, `channel`, `is_weekend` y `num_hrefs_cat`, mientras que `n_tokens_content_cat` muestra un efecto más limitado. Estos resultados refuerzan la idea de que la popularidad no depende de una única característica, sino de la combinación de varios factores dentro del modelo.

5.4 Capacidad predictiva del modelo

La capacidad predictiva del modelo se evalúa a partir de las métricas obtenidas durante la validación cruzada. Aunque el Accuracy ofrece una visión global del porcentaje de aciertos, en este problema resulta especialmente relevante observar el Balanced Accuracy y el AMAE, ya que la variable respuesta presenta clases desbalanceadas y una estructura ordinal.

```
##   criterio           metrica     media desviacion_tipica
## 1  Ord-MAP              AMAE 0.9445136       0.010374768
## 2  Ord-MAP               MAE 0.7069396       0.007135037
## 3  Ord-MAP          Accuracy 0.4352233       0.005887157
## 4  Ord-MAP Balanced_Accuracy 0.2979763       0.005994345
```

El modelo principal obtiene un rendimiento competitivo respecto los otros, por eso y por parsimonia es por lo que lo hemos elegido, pero viendolo individualmente no parece un modelo especialmente bueno. Por ejemplo, fijandonos en el AMAE, la métrica principal, vemos que es de 0.9445, con 4 clases a predecir el rango del AMAE va de 0 a 3, es decir, el error medio de clasificación es menor a 1 categoría de distancia, un valor que podríamos considerar demasiado alto. Sin embargo, a la vez el resultado es bueno porque al tratarse de fenómenos y comportamientos sociales, suele ser difícil encotrar métricas al nivel que las que encontraríamos para estudios más científicos, técnicos o experimentales. Es por eso, que el valor AMAE cercano a 1, no resulta tan negativo bajo este contexto de datos.

```
##           Observada
## Predicha   muy_baja  baja media  alta
##   muy_baja     2701  1823   322   265
##   baja         8582 13177  3564  3491
##   media         723  1548   667   996
##   alta           90   222    97   195
```

La matriz de confusión global revela una clara sobreestimación hacia la clase mayoritaria (baja) en las predicciones del resto de variables. Además, el desbalance dificulta una evaluación visual directa y objetiva de la matriz, haciendo necesario recurrir a las métricas ya comentadas para determinar la validez real del modelo

5.5 Estudio de predicciones

Casos inventados

Los casos inventados los hemos hecho en base a tres perfiles diferenciados: uno potencialmente favorable, uno claramente desfavorable y uno mixto. El objetivo es observar cómo cambian las probabilidades posteriores del modelo ante combinaciones distintas de características.

Table 19: Predicciones casos inventados (parte 1)

caso	channel	is_weekend	n_tokens_content_cat	num_hrefs_cat	kw_avg_avg_cat
Perfil potencialmente favorable	socmed	1	corto	muchos	alta
Perfil claramente desfavorable	world	0	largo	pocos_ninguno	baja
Perfil mixto	business	0	largo	muchos	alta

Table 20: Predicciones casos inventados (parte 2)

caso	prediccion_OrdMAP	prediccion_MAP	P_muy_baja	P_baja	P_media	P_alta
Perfil potencialmente favorable	media	alta	0.0136	0.3148	0.2761	0.3955
Perfil claramente desfavorable	muy_baja	muy_baja	0.5848	0.3405	0.0450	0.0297
Perfil mixto	baja	baja	0.1555	0.4074	0.1866	0.2505

En el perfil potencialmente favorable, la mayor probabilidad posterior corresponde a la clase `alta`, aunque el criterio Ord-MAP predice `media`, mostrando una clasificación más moderada al tener en cuenta el orden de las categorías. En cambio, el criterio MAP selecciona directamente la clase con mayor probabilidad.

En el perfil claramente desfavorable, ambos criterios coinciden en predecir `muy_baja`, con una probabilidad posterior claramente dominante. Esto indica que el modelo identifica este perfil como un caso de baja popularidad.

Finalmente, en el perfil mixto, ambos criterios predicen `baja`. Aunque existen probabilidades relevantes en `media` y `alta`, el conjunto de características no es suficiente para desplazar la predicción hacia niveles superiores.

En conjunto, este análisis ilustra que el modelo asigna la popularidad combinando las cinco variables disponibles.

Casos de combinaciones no existentes en la base de datos categorizada

Nos dimos cuenta también que podrían existir combinaciones de categorías de las variables predictoras, una vez categorizadas, que podrían no haber aparecido en nuestra base de datos categorizada. Dado esto, debíamos investigar estos casos para saber como se comportaba el modelo en estos casos y si la cantidad de combinaciones faltantes era excesiva. Con 5 variables predictoras con 7, 2, 3, 3 y 3 clases posibles, son un total de 378 combinaciones posibles de clases.

Table 21: Predicciones casos que no aparecen en la BD (parte 1)

	caso	channel	is_weekend	n_tokens_content_cat	num_hrefs_cat	kw_avg_avg_cat
81	Caso nuevo 1	other	1	largo	moderados	baja
87	Caso nuevo 2	lifestyle	0	corto	muchos	baja
89	Caso nuevo 3	socmed	0	corto	muchos	baja
92	Caso nuevo 4	business	1	corto	muchos	baja
93	Caso nuevo 5	entertainment	1	corto	muchos	baja
94	Caso nuevo 6	lifestyle	1	corto	muchos	baja
95	Caso nuevo 7	other	1	corto	muchos	baja
96	Caso nuevo 8	socmed	1	corto	muchos	baja
165	Caso nuevo 9	other	1	largo	pocos_ninguno	media
218	Caso nuevo 10	business	1	corto	muchos	media
219	Caso nuevo 11	entertainment	1	corto	muchos	media
220	Caso nuevo 12	lifestyle	1	corto	muchos	media
224	Caso nuevo 13	world	1	corto	muchos	media
288	Caso nuevo 14	business	1	largo	pocos_ninguno	alta
349	Caso nuevo 15	tech	1	corto	muchos	alta

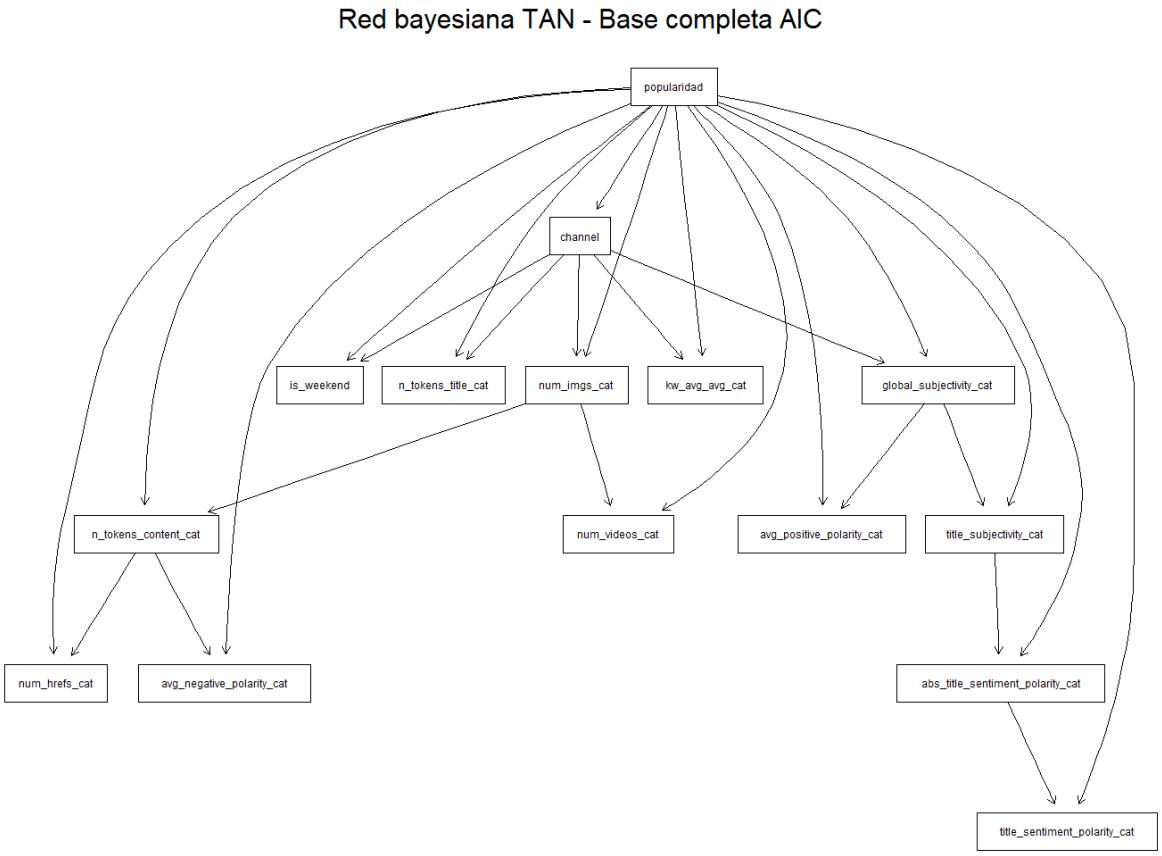
Table 22: Predicciones casos que no aparecen en la BD (parte 2)

	caso	prediccion_OrdMAP	prediccion_MAP	P_muy_baja	P_baja	P_media	P_alta
81	Caso nuevo 1	baja	baja	0.1472	0.5063	0.1911	0.1554
87	Caso nuevo 2	baja	baja	0.2882	0.4601	0.1060	0.1457
89	Caso nuevo 3	baja	baja	0.1387	0.5313	0.1697	0.1602
92	Caso nuevo 4	baja	baja	0.1593	0.5519	0.1714	0.1174
93	Caso nuevo 5	baja	baja	0.2315	0.5005	0.1194	0.1487
94	Caso nuevo 6	baja	baja	0.1078	0.5349	0.1692	0.1882
95	Caso nuevo 7	baja	baja	0.1114	0.4251	0.1881	0.2754
96	Caso nuevo 8	baja	baja	0.0452	0.5383	0.2361	0.1803
165	Caso nuevo 9	baja	baja	0.0912	0.4511	0.2169	0.2407
218	Caso nuevo 10	baja	baja	0.0974	0.5253	0.2102	0.1671
219	Caso nuevo 11	baja	baja	0.1450	0.4881	0.1500	0.2168
220	Caso nuevo 12	baja	baja	0.0628	0.4847	0.1975	0.2550
224	Caso nuevo 13	baja	baja	0.1611	0.5447	0.1510	0.1432
288	Caso nuevo 14	baja	baja	0.0830	0.4671	0.2446	0.2053
349	Caso nuevo 15	media	baja	0.0326	0.3668	0.2489	0.3516

Como vemos, hay 15 combinaciones de categorías que no aparecen en la base de datos categorizada. Dado que existen 378 combinaciones posibles, estos casos representan aproximadamente un 3.97% del total, por lo que la base de datos cubre la gran mayoría de perfiles posibles entre las variables predictoras seleccionadas.

Al analizar las predicciones para estos casos no observados, vemos que tanto el criterio OrdMAP como el criterio MAP suelen asignar la clase baja, aunque en el último caso la predicción és de popularidad media (según el criterio OrdMAP, que es el del modelo final escogido). Esto nos indica que el modelo parece ser capaz de generar predicciones razonables incluso para combinaciones que no estaban presentes en los datos originales (y por tanto los de entrenamiento del modelo), manteniendo un comportamiento coherente con la distribución general de la variable objetivo.

6 Modelo secundario: relaciones entre predictoras



Hemos escogido el modelo TAN de la base de datos completa como modelo secundario del estudio, ya que ha resultado estadísticamente igual que el mejor de los modelos de la base de datos completa según la métrica de validación AMAE, que era un Naive Bayes, igual que el mejor de la base reducida. Sin embargo, ya hemos hablado anteriormente de las limitaciones interpretativas de un Naive Bayes y por lo tanto, este Tree Augmented Naive Bayes, aunque también tiene restricciones, nos puede servir para interpretar las relaciones entre las variables.

Lo primero que notamos y más destacable es que la variable `channel` es padre de hasta otras cinco variables. Esto destaca porque los siguientes padres con más hijos (exceptuando popularidad) tan solo tendran dos hijos. De los hijos de `channel` vemos que dos estan en la base reducida: `is_weekend` y `kw_avg_avg_cat`. Aunque es entendible que las palabras clave dependan del canal de publicación, nos ha resultado curioso que el hecho de que se publique en fin de semana o no también, además hay que tener en cuenta que publicar en fin de semana era un factor positivo para la clasificación de popularidada del artículo.

Sobre las otras dos variables que aparecen en el modelo reducido, podemos notar que la variable `num_hrefs_cat` es hija de `n_tokens_content_cat`, lo cual tiene un sentido lógico: a más largo el texto, más hiperlinks. Pero curiosamente también notamos que el otro hijo de `n_tokens_content_cat` es `avg_negative_polarity_cat`, es decir, la polaridad negativa del texto depende de lo largo que sea, cosa que no pasa con `avg_positive_polarity_cat`.

Finalmente, notamos como el resto de variables de subjetividad y polaridad (excepto `avg_negative_polarity_cat`) estan "apartadas" y son interdependientes entre ellas. Este resultado es coherente, ya que se trata de variables conceptualmente próximas, todas ellas vinculadas al tono, la subjetividad y la carga emocional

del texto. Por tanto, el modelo TAN sugiere que estas características no aportarían información de manera completamente independiente, sino que tienden a agruparse y relacionarse entre sí.

Recalcar que todas estas relaciones deben interpretarse como asociaciones estadísticas útiles para la clasificación dentro del modelo TAN, y no como relaciones causales directas entre los aspectos/variables del artículo.

7 Análisis complementario: estudio de asociación entre predictoras y respuesta

7.1 Motivación del análisis complementario

Como complemento al modelo principal, hemos realizado un análisis bivariante entre cada variable predictora del conjunto reducido y la variable respuesta popularidad. El objetivo es cuantificar hasta qué punto cada variable está asociada individualmente con los niveles de popularidad, aunque sin tener en cuenta el efecto conjunto del resto de predictoras.

Para ello, se emplea el test chi-cuadrado de independencia, donde buscaremos que NO haya independencia y la V de Cramer como medida de intensidad de la asociación. Además, hemos calculado la diferencia entre el porcentaje mínimo y máximo de artículos de popularidad alta dentro de los niveles de cada variable, lo que facilita una interpretación más directa de su relación con la clase de mayor interés.

Cabe recalcar, que este análisis complementario se situa fuera del modelo, es un análisis que, por ejemplo, podríamos haber realizado durante la selección de variables y haberlo utilizado como método de aceptación o rechazo de variables. Sin embargo, al final del estudio también tiene un sentido ya que nos sirve para verificar, comprobar y solidificar el trabajo realizado.

7.2 Resultados

```
##               variable chi_cuadrado grados_libertad    p_valor p_valor_ajustado
## 5       kw_avg_avg_cat    2228.5734               6  0.000e+00        0.000e+00
## 1              channel    3006.1041              18  0.000e+00        0.000e+00
## 2           is_weekend     946.9449               3 5.809e-205       1.743e-204
## 4        num_hrefs_cat     549.6607               6 1.671e-115       3.342e-115
## 3 n_tokens_content_cat     136.0322               6  6.886e-27        6.886e-27
##   v_cramer pct_alta_min pct_alta_max diferencia_pct_alta
## 5   0.1702         6.53        23.26               16.73
## 1   0.1614         7.04        24.06               17.02
## 2   0.1569        12.30        16.59                4.29
## 4   0.0845        10.57        18.64                8.07
## 3   0.0421        11.51        14.77                3.26
```

La tabla resume la asociación entre cada predictora del conjunto reducido y popularidad. Los p-valores con valor 0, deben interpretarse como <0.00001, es simplemente que numéricamente R tiene un límite de decimales. Los p-valores ajustados de los test chi cuadrado nos permiten comprobar si la relación es estadísticamente significativa tras corregir por comparaciones múltiples, y como podemos observar, todos son valores muy cercanos a 0, por lo que rechazamos la hipotesis nula en favor de la alternativa que nos dice que las variables son dependientes. Como decía, es lo lógico y esperable, justamente han aparecido varias o muchas veces en el Markov Blanket de popularidad por tener relación con esta, podrían haber aparecido por azar, ciertamente, y en ese caso este test nos hubiese ayudado a descubrirlo.

Por otro lado, la V de Cramer nos sirve para cuantificar la intensidad de la asociación, donde 0 es que nada y 1 asociación máxima. En este sentido, podríamos pensar que los valores de la V de Cramer son bajos, pero como ya hemos comentado este se trata de un estudio de tipo sociológico y no debemos esperar encontrar métricas del nivel que esperaríamos con datos científicos, técnicos o experimentales, donde podríamos exigir mayores valores. Igualmente, también es relevante ver como las tres primeras variables tienen valores cercanos entre sí (alrededor del 0.16), mientras que la cuarta baja a la mitad (0.08) y la quinta se reduce otra vez a la mitad.

8 Conclusiones

En este trabajo se ha abordado la clasificación de la popularidad de artículos online de la revista Mashable mediante redes bayesianas, partiendo de una variable original, `shares`, fuertemente asimétrica y con valores extremos. La transformación de esta variable en `popularidad`, con cuatro niveles ordenados (`muy_baja`, `baja`, `media` y `alta`), ha permitido plantear el problema como una tarea de clasificación ordinal.

El proceso de selección de variables mediante Markov Blanket nos ha permitido construir dos conjuntos de datos: una base completa y una base reducida.Tras comparar diferentes modelos y criterios de clasificación, se ha seleccionado como modelo principal un Naive Bayes con criterio Ord-MAP entrenado sobre la base reducida. Esta elección se fundamenta en su rendimiento competitivo en términos de AMAE y en su mayor parsimonia. Aunque el modelo no presenta una capacidad predictiva perfecta, el error medio se sitúa por debajo de una categoría de distancia, lo cual resulta razonable teniendo en cuenta que se trata de datos de naturaleza sociológica.

La interpretación del modelo muestra que `kw_avg_avg_cat` es una de las variables más relevantes para discriminar entre niveles de popularidad, seguida de variables como `is_weekend`, `num_hrefs_cat` y `channel`. En cambio, `n_tokens_content_cat` presenta una capacidad discriminativa menor, lo que sugiere que la longitud del contenido, por sí sola, no es uno de los factores más determinantes.

Como complemento, el modelo Tree-Augmented Naive Bayes sobre la base completa ha permitido explorar relaciones entre predictoras que el Naive Bayes no puede representar. Además, el análisis bivariante mediante chi-cuadrado y V de Cramer ha reforzado la importancia de variables como `kw_avg_avg_cat`, `channel` e `is_weekend`, que presentan las asociaciones más intensas con `popularidad`.

En conjunto, los resultados muestran que los modelos bayesianos permiten aproximar de forma útil la popularidad de artículos online, combinando capacidad predictiva e interpretabilidad. No obstante, las relaciones identificadas deben entenderse como asociaciones estadísticas y patrones predictivos, no como relaciones causales directas, ya que la popularidad depende también de factores externos no recogidos en la base de datos.

9 Limitaciones y propuestas de mejora

Para comenzar, a nivel de código utilizado en este proyecto, existe un grave problema de duplicación de este. Es decir, hay mucho código muy parecido que se escribe una y otra vez. Por ejemplo, cada modelo tiene su propia parte del código pero estas son muy similares entre sí, generando una gran extensión que da pie a errores tipográficos que podrían ser muy difíciles de localizar. Por lo tanto, sería conveniente crear más funciones auxiliares para los bloques de entrenamiento y validación que nos permitieran definir estas partes extensas una sola vez y posteriormente hacer uso de estas funciones tantas veces como fuera necesario. Sin embargo, por nuestros recursos y por falta de tiempo se desestimó esta opción.

Siguiendo en la línea del código empleado, podemos apreciar cómo durante el proceso de entrenamiento de las diferentes propuestas de modelos, hay muchos objetos que se sobrescriben. Esto fue provocado por el punto anterior, cómo tenemos mucho código repetido, consideramos que era mejor no alterar los nombres de los objetos para reducir el riesgo de errores tipográficos, es decir, no nombrar objetos específicos para cada paso, sino asignarles nombres genéricos y compartidos, y que de esta manera solo se mostraran durante el proceso y luego quedaran "eliminados" (mejor dicho, sobrescritos). Esto presentó un pequeño problema en el momento de redactar el informe, ya que nos dimos cuenta de que algunos de esos objetos que teníamos printeados en el código pero no guardados, queríamos que aparecieran en el informe. Esto nos obligó a volver al código y guardar estos resultados intermedios deseados en objetos nuevos. Aunque pudimos solucionarlo satisfactoriamente, es un punto a tener en cuenta en proyectos futuros.

Dicho inconveniente fue producido principalmente también por el sistema utilizado para enlazar resultados en el informe. Nosotros decidimos utilizar un `.RData` para cargar los objetos que nos fueran necesarios del código en el archivo .Rmd donde se redactó el presente informe. Esta decisión, aunque óptima y de gran aprendizaje para nosotros, fue tomada en respuesta a otra gran limitación que nos encontramos: el código del proyecto terminó por convertirse en algo muy pesado y lento. Por esta razón, se hacía muy difícil trabajar directamente con dicho código porque suponía mucho tiempo de espera. Gracias al archivo `.RData` pudimos ejecutarlo una sola vez (después de seleccionar y añadir los objetos que deseábamos guardar) y trabajar directamente con los resultados para redactar el informe. Somos conscientes de la carga computacional que supone nuestra propuesta:

- Por una parte, en el proceso de selección de variables mediante Markov Blanket, intervienen dos procesos bootstrap donde se aprenden un total de 200 redes bayesianas mediante Hill-climbing, en el cual además de especificaron varios puntos de inicio y perturbaciones (`restart = 20`, `perturb = 5`). Con lo cual se sacrificó la eficiencia computacional en favor de la estabilidad.
- Por otra parte, la gran cantidad de propuestas entrenadas sobre cada uno de los 10 folds que hacen un total de 10 folds x 3 modelos x 2 conjuntos de predictoras = 60 procesos, incrementando además de complejidad partiendo de un modelo simple computacionalmente a otros 2 cada vez más costosos.

En cuanto a metodología estadística empleada, nos queda la duda de si nuestra selección Markov Blanket mediante criterio AIC es demasiado permisiva. Tanto cuando se utilizó criterio BIC como AIC, el criterio de selección fue como mínimo de una aparición, el cual en el proceso con AIC nos parece que posiblemente es demasiado laxo. Por lo tanto, proponemos si como futura continuación de este proyecto podría considerarse establecer un criterio menos permisivo como un porcentaje de aparición, para compensar la permisividad que ya aporta el criterio AIC.

Como comentario adicional, se planteó la posibilidad de aprovechar todo el proceso de entrenamiento realizado para estudiar la efectividad de cada criterio de predicción, ya que se propuso y validó tanto el criterio apropiado para el problema ordinal OrdMAP, como el simple para multi-clase MAP. Aunque de alguna forma ya se ha comparado, se ha hecho de manera general con comparaciones globales de propuestas, sin embargo sería interesante realizar otro análisis complementario de comparaciones apareadas entre el mismo tipo de modelo pero ambos criterios.

Por último, debemos mencionar y debatir sobre la adecuación de las redes bayesianas a nuestros datos concretos. Partíamos de una base de datos mayoritariamente numérica, por lo que el proceso de categorización

aplicado puede haber supuesto una importante pérdida de información. Después de una pequeña búsqueda de proyectos similares sobre los mismos datos, encontramos algunos estudios realizados mediante modelos lineales. Por lo que podría estudiarse esta suposición mediante una comparación, puramente informativa y de interés personal, utilizando los resultados obtenidos en dichos estudios.